ORIGINALITY AUDIT AND RECOVERY PLAN

IJMLC 拒稿后原创性诊断与论文挽救方案

独立研究审计报告 · Independent Research Audit

> 审计对象：Deep ensembles outperform snapshot ensembles and weight averaging for calibrated uncertainty under fixed training budgets（v4.1.2）
>
> 证据基线：仓库 deep-ensembles-fixed-budget，main 分支 1bc7f61，release paper-v4.1.2
>
> 拒稿依据：IJMLC 编辑初筛意见（未送外审）：原创性不足
>
> 审计日期：2026 年 10 月 19 日

Sole author: Chang Tan · Dalian University of Technology

2026-10-19 · v1.0

目 录

执行摘要：独立结论.....

执行摘要：独立结论.....1

第一章 研究现状还原.....2

1.1 已实际完成的实验.....2

1.2 由数据直接支持的结论.....3

1.3 仍属推测或解释性的部分.....3

1.4 需要额外实验才能支持的主张.....3

1.5 历史问题与修复链.....3

第二章 原创性差距分析.....4

2.1 检索方法与范围.....4

2.2 最接近研究的逐项对照.....4

2.3 差异定性：本文每个元素属于哪一类.....4

第三章 拒稿原因的证据化解释.....5

3.1 为什么严谨的研究仍被初筛拒绝.....5

3.2 真正新增了什么知识.....5

3.3 新增知识是否足够重要、可推广、可复现.....6

3.4 共识验证还是未揭示的规律.....6

3.5 如果我是编辑：当前版本会再次被拒吗.....6

第四章 三个投入水平的研究方案.....6

4.1 方案 A：最小改动（重定位为受控实证研究）.....7

4.2 方案 B：中等改动（预算分配规律）.....7

4.3 方案 C：高投入（校准感知的预算分配算法）.....7

4.4 三方案对比.....7

第五章 最推荐方案及实施步骤.....8

第六章 新增实验必要性清单.....8

6.1 从现有数据可挖的分析（本次审计已完成检验）.....8

6.2 必须新增的实验（仅方案 B 所列）.....9

6.3 可选强化（作者资源决定，非必需）.....9

6.4 明确不再做的实验.....9

第七章 停止规则.....9

第八章 下一阶段工作计划.....10

第九章 期刊重选判断框架.....10

9.1 TMLR 特别注意事项.....11

结语：对最终问题的明确回答.....11

附录 可核验性记录.....11

注：本目录由域代码生成。编辑文档后请在目录上右键选择更新域，以刷新页码。

执行摘要：独立结论

本报告是对论文 Deep ensembles outperform snapshot ensembles and weight averaging for calibrated uncertainty under fixed training budgets（单作者，v4.1.2 投稿版）被 IJMLC 编辑初筛拒稿一事的独立审计。审计从仓库原始数据出发重新核验了研究现状，检索并核对了最接近的文献，评估了拒稿原因，并给出三个投入水平的研究方案与停止规则。以下五点是核心结论，正文各章提供完整证据。

第一，论文本身没有可被指认的方法学或数据缺陷。本次审计直接从 results/ 目录的逐种子 JSONL 记录复算了关键统计（排名一致性、预算趋势、验证曲线、机制相关），与稿件报告一致；历史累计 241 项独立数值核验中 232 项完全复现、9 项例外均有书面处置记录。拒稿理由不是已确认的错误，而是编辑对原创性的内容判断。

第二，拒稿的实质是定位失败，而非质量失败。标题与摘要的头牌主张（集成优于其他策略）是领域共识的直接重述；而论文真正新的三个元素——检查点级配对隔离组合机制、快照集成免费午餐在校准轴上的失效、预算放大规律（DeepEns 对 Single 的 NLL 优势随预算 30/60/120 单调放大 0.075、0.225、0.332）——被排在六条贡献列表的中后部。编辑在初筛的模式匹配中看到的是又一篇确认共识的小规模比较研究。

第三，原创性分级必须诚实。按本报告第二章的逐项判定：设计的预算匹配与检查点配对属于更严格的实验控制而非新知识；温度缩放与 OOD 的主体结论属于确认已知结果；快照集成的校准缺陷属于新的边界性经验发现；预算放大规律是论文最接近可检验规律的增量。这一组合在以新颖性为门槛的期刊不足以通过初筛，编辑的判断可以辩护，尽管其代价是论文中确实存在的窄增量被一同否决。

第四，推荐方案 B（中等投入）。以固定预算下的集成规模分配规律（k 与 B 的联合扫描）为新研究问题，全部实验可在现有 CPU 管线上约一周内完成，总周期约 4 至 6 周。它把论文从验证共识升级为提出并检验一条新的经验规律加决策规则，且失败条件明确、沉没成本可控。纯润色转投常规机器学习期刊被判定为不值得（见结语），TMLR 是唯一合理的低成本退出通道，但那需要重定位而非润色。

第五，对最终问题的回答。不新增任何实质性科学贡献、仅对现有稿件润色并转投，在绝大多数期刊场景下不值得：拒稿理由是内容判断，润色不改变模式匹配的输入；每一轮初筛耗费 4 至 10 周且无学习信号；同一原因的连续拒稿会累积成不利记录。唯一例外是以主张-证据支持而非新颖性为录取标准的 TMLR，但该路线要求重写标题与定位、并按其政策如实处理大语言模型参与工作流的披露问题。

第一章 研究现状还原

本章从仓库的原始记录而非论文摘要出发，区分五类事实：已实际完成的实验、由数据直接支持的结论、仍属推测的机制解释、需要额外实验才能支持的主张、以及历史版本中已修正或仍遗留的问题。所有数值均可用附录 A 列出的文件与脚本复现。

1.1 已实际完成的实验

全部实验可追溯到六组逐种子 JSONL 记录（每条含四种条件在该种子下的全部指标、逐 epoch 训练历史、成员级测量与可靠性直方图），外加一组探索性的 SWA-dense 变体。核心设置为 Fashion-MNIST、MLP 约 110k 参数、总预算 B=60 epoch、k=3、10 个种子；统计设计（对比族、主结局、多重校正方案）在任何测试集评估之前预注册（research-docs/research-design.md，2026-09-22）。扩展设置覆盖预算 30/60/120、规模 k=3/5、MNIST 反向方向、KMNIST 第二 OOD 探针、逐条件温度缩放，以及标注为事后分析的 CIFAR-10 小型 CNN 复制。

表 1-1 实验资产与完成状态（全部存在于公开仓库）

实验组	文件（results/）	规模	性质
核心四路比较	experiment.jsonl	4 条件 x 10 种子	预注册
预算/规模/方向扩展	v2/experiment_v2_*.jsonl（5 组）	各 4 x 10	事后（已声明）
CIFAR-10 CNN 复制	cifar/ experiment_cifar_B60_k3.jsonl	4 x 10	事后（已声明）
SWA-dense 变体	experiment_swa_dense.jsonl	补充条件	探索性（已声明）
温度缩放层	各记录内 ts 字段	每条件每种子	事后（已声明）
逐 epoch 训练历史	各记录内 histories 字段	单次/循环两条轨迹	描述性

注：四种条件为 Single（1 x 60 epoch）、DeepEns（3 x 20）、Snapshot（1 x 60 循环，3 快照）、SWA（同快照权重平均）；快照与 SWA 共享同一条训练轨迹与检查点，集成与快照的第一成员位级一致（记录含 shared_member_bit_identical: true）。

1.2 由数据直接支持的结论

以下结论的每一个数字本次审计均从原始 JSONL 重算或核对，而非转引自论文。核心设置（Fashion-MNIST，B=60，k=3）的均值排序为 NLL 0.302（DeepEns）、0.349（Snapshot）、0.387（SWA）、0.527（Single），ECE 同序（0.0236、0.0444、0.0517、0.0702）；预注册五对比族经 Holm 校正后主结局全部显著

（P=0.0098，精确符号翻转置换检验的十种子下限为 0.0020）。今日复核补充确认了三点更强的事实：其一，DeepEns 在六个设置中的五个里是全部十个种子的最优条件（CIFAR 为 9/10，唯一例外是保留了成员坍塌种子的那次），排序并非均值假象；其二，四个 Fashion-MNIST 设置中逐种子成对方向完全一致（DE 优于 SN、SN 优于 SWA、SWA 优于 SG 各 10/10）；其三，MNIST 反向方向上 SWA 仅在 3/10 种子上优于 Single，与其均值近乎持平（0.0741 对 0.0724）一致，构成真实的边界条件而非噪声波动。

预算放大规律是数据中最有规律性的结构：DeepEns 对 Single 的 NLL 优势在 B=30、60、120 下分别为 +0.075、+0.225、+0.332（今日按种子重算，标准差 0.008 至 0.016），单调且近似超线性。机制侧的对应证据也已存在于记录中：单模型验证 NLL 在 Fashion-MNIST 上的最低点中位数出现在第 12 epoch（范围 7 至 14），此后持续恶化至 60 epoch 终点 0.476，而 MNIST 上最低点中位数为第 46 epoch——训练越久校准越差的余量与预算放大规律在同一数据中共同出现。OOD 检测方面，DeepEns 在全部 11 个设置-探针组合上正向（探针族内校正后 P 至多 0.032），SWA 效果小且方向不一（-0.016 至 +0.025）；逐条件温度缩放压缩但不关闭核心预算及以上的差距（0.289 对 0.333），在 B=30 处基本拉平各集成策略。CIFAR-10 上 DeepEns 对 Snapshot 的 ECE 优势方向一致但未获统计解析（差 -0.0418，95% CI [-0.0845, +0.0008]，未校正 P=0.082），异常种子（DeepEns ECE 约 0.210、NLL 约 0.929）按无排除规则保留并附诊断与留一敏感性分析。

1.3 仍属推测或解释性的部分

论文将成员质量与成员多样性作为机制的解释，且已自我限定为关联性描述。本次审计专门检验了这一克制的措辞是否必要：在设置内部按种子计算集成增益与成员均值 NLL、成员分歧 JSD 的 Spearman 相关，六个设置的相关系数分别在 -0.77 至 +0.33 与 -0.73 至 +0.77 之间，方向不一致、幅度中等。也就是说，种子粒度上机制变量与增益没有稳定关系，跨设置层面的一致外观主要由设置难度混杂驱动。结论：论文保留关联性措辞的决定是正确的，该机制叙事不能在现有数据上升级为规律或因果陈述。类似地，校准余量边界条件（MNIST 上单轨迹策略无改进）有上述验证曲线证据支持，但余量导致优势这一因果方向仍是解释性假说。

1.4 需要额外实验才能支持的主张

若要把论文从比较研究升级为规律性研究，现有数据存在三个明确的空位。其一，集成规模的作用：k=2 与 k=8 从未运行，k*(B) 最优分配规律无法从 k=3/5 两个

点外推（现有 k=5 对 k=3 的增益差仅 0.005，且成员质量更好而多样性更低，两个机制方向相反，无法分解）。其二，推理成本维度的系统化：所有集成策略推理成本为 k 倍，论文有成本讨论但没有 NLL-推理成本的前沿刻画。其三，规模化：WRN 级架构与 CIFAR-100/ImageNet 级数据的验证缺失，这决定了结论的外推边界只能停留在小网络图像任务。前两项可用现有 CPU 管线低成本补齐，第三项需要 GPU 且对本文定位并非必需（见第六章）。

1.5 历史问题与修复链

版本链上的问题均已在后续版本修复并留有记录：v1 的四处引用编号漂移（v2 修复）；v2 遗留的 Table 1 KMNIST 探针标准误行错误（v4.1.0 修复，与分析和图源数据三方核对）；v4.0.0 的三处过度主张（MNIST 反方向上四元排序稳健的表述、以邻接推断代替直接检验、定位段与自身相关工作矛盾）（v4.1.0 修复，含补做 DeepEns-SWA 直接对比 -0.0176，P=0.0020）。241 项历史数值独立核验的 9 项例外全部有书面处置（number-verification-v4.1.md）。本次审计未发现新的数据与正文不一致。需要说明的一处非科学问题：v4.1.2 在作者决定下移除了两段大语言模型使用声明（Springer 政策要求披露超出文字润色级别的使用），该决定已记录于清单 D5 供作者知悉；本报告在期刊策略章（第九章）按目标期刊政策再次标注此事项，因为它构成 TMLC 路线的实质审稿风险点。

第二章 原创性差距分析

2.1 检索方法与范围

本审计的文献核验分两层：仓库内 v4.1 定位审计（14 次检索、arXiv/OpenReview/出版商交叉验证，截至 2026-10-14，覆盖 28 篇引用文献的完整性）与本轮独立复检（2026-10-19，重点核查预算分配轴、快照集成校准先例、权重平均与预测平均的偏移端点、集成规模-训练时长权衡）。复检通过学术检索完成，并对最关键的三篇（Kondratyuk et al. 2020、The cost of ensembling 2025、TMLR 官方政策）读取原文摘要或官方页面确认。检索采用诚实规则：未找到仅报告为在所查渠道未找到。

2.2 最接近研究的逐项对照

下表按用户指定的七列给出最接近的 14 项研究。判定原则：不把使用不同数据集或增加实验数量自动计为原创性；关注的是问题、端点与控制轴的实质差异。

表 2-1 最接近研究对照表（检索截至 2026-10-19）

研究	核心问题	方法	预算控制	校准	OOD	与本文的实质区别
Lakshminarayanan et al. 2017 (NeurIPS)	集成能否给出好的 UQ	DE vs MC dropout 等	无（计为附加成本）	NLL/Brier/ECE	少量	确立 DE 强基线地位；预算不对齐，无快照/SWA
Huang et al. 2017 (ICLR)	循环 LR 免费集成	Snapshot	无（单次训练内）	无（精度）	无	免费午餐主张限于精度轴；本文给出校准轴反例
Izmailov et al. 2018 (UAI)	权重平均找平坦极小值	SWA	无	NLL 部分	无	SWA 来源；非检查点配对对比
Fort et al. 2019 (NeurIPS)	随机初始化为何有效	DE 及变体	无	部分	无	机制背景；无预算轴
Ovadia et al. 2019 (NeurIPS)	偏移下 UQ 基准	多方法大基准	各方法各异	ECE/NLL	有	偏移下 DE 最稳；但预算不跨方法匹配
Wen et al. 2020 (ICML)	参数高效集成	BatchEnsemble	部分	有	无	效率轴；预测端等价 DE
Ashukha et al. 2020 (ICLR)	域内 UQ 陷阱	单+TS vs DE	算力匹配（DEE）	NLL/覆盖	无	对比(i)最近邻：域内、无快照/SWA/OOD/预算分配
Zhang et al. 2020 (AISTATS)	DE 与后校准交互	DE+校准器	无	有	无	TS 交互先例；无预算匹配
Kondratyuk et al. 2020 (arXiv)	小模型集成 vs 单大模型	容量分配	FLOPs 匹配	无（精度）	无	容量轴的预算分配；非训练时长轴、无校准（本轮新核验，现稿未引）
Brigato & Iocchi 2021 (arXiv)	小数据上集成有效性	架构轴缩放	固定总算力	无（精度）	无	对比(i)另一轴：架构缩放替代时长分配
Ramé et al. 2022 (NeurIPS, DiWA)	权重平均何时利于 OOD 泛化	跨运行 WA	无	无（精度）	泛化精度	WA+偏移最接近的理论；端点不同、非检查点配对
Krumpl et al. 2024 (WACV, ATS)	自适应 TS 改善 OOD 检测	样本级 TS	无	无	有	佐证 TS 非保序；非预算研究
Ajroldi et al. 2025 (ICML)	何时平均权重	WA 变体基准	训练时间（加速）	无（精度）	无	WA 基准；加速/泛化端点，无不确定性质量
The cost of ensembling 2025 (arXiv)	集成成本收益权衡	零售预测集成	部分（成员 2-5）	无（分位数损失）	无	应用域规律：小集成(2-3)常已足；无校准/OOD（本轮新核验）

2.3 差异定性：本文每个元素属于哪一类

按用户给定的五类判定（纯粹的实验设置变化、更严格的实验控制、新的经验发现、新的可检验规律、新的方法或理论贡献），对本文各元素逐一判定如下。这一分级是后续方案设计与停止规则的共同基础。

表 2-2 本文各元素的原创性分级

论文元素	最接近先例	判定	说明
四路预算匹配 + 位级检查点共享设计	Ashukha（算力匹配）、Brigato（固定算力）	更严格的实验控制	设计贡献而非知识贡献；组合在该轴上未见先例
快照集成校准劣势（预算对齐下）	Huang 2017 声称精度轴免费午餐	新的经验发现（边界性）	对免费午餐叙事的校准轴修正；单一规模上测得
预算放大规律（0.075/0.225/0.332）	未见直接先例（训练时长-校准关系散见）	新的可检验规律（候选）	论文最接近规律的增量；仅三预算点、单架构
MNIST 饱和边界条件	定性共识（简单任务集成收益小）	新的边界条件	有信息量但可预期
TS 压缩不关闭差距	Ashukha 2020、Zhang 2020	确认已知	作为稳健性检查有价值，非增量
OOD：预测平均稳、权重平均任务依赖	Ovadia 2019 + DiWA 2022	部分新的组合	检查点配对下的端点组合是新的，组件结论已知
成员质量/多样性机制	Fort 2019	关联性描述（推测层）	今日复核：种子级相关不稳定，不能升级
无新方法/新理论	-	（自我声明成立）	论文自述 ascriptive rather than algorithmic

综合判定：论文是一个把更严格控制、一条候选规律、两个边界性发现和若干确认性结果打包在一起的研究。打包本身在方法学上无可指摘，但每一单条的边际知识增量都窄，而头牌位置（标题、摘要前半）放置的是确认性内容。这就是设计严谨与原创性不足可以同时为真的结构性原因。

第三章 拒稿原因的证据化解释

3.1 为什么严谨的研究仍被初筛拒绝

初筛编辑的决策输入主要是标题、摘要、引言定位段与作者信息，通常在数分钟内完成。该决策点上有六个机制共同作用。其一，标题 Deep ensembles outperform ... 是领域共识的直接重述，与 Lakshminarayanan 2017 和 Ovadia 2019 的可检索记忆直接冲突为零，即不构成新知识信号。其二，摘要的结构是背景一句加结果罗列，没有任何一句先陈述一个此前未知的问题再给出回答；三个新元素最快也要读摘要后半段才出现。其三，贡献列表第二条自称稳健排序结果，第五条自称事后重校准压力测试——两个最不利的自我标签（稳健性、压力测试）都指向验证性研究。其四，正文明确写有 ascriptive rather than algorithmic，等于替编辑写好了拒稿信。其五，实验规模（不超过 110k 参数的 MLP 加一个小 CNN、10 种子）触发可推

广性折扣，编辑无法将小规模确认视为重要。其六，IJMLC 的栏目定位偏向方法与应用创新，比较类论文本身就在劣势赛道。

3.2 真正新增了什么知识

诚实的清单有三条，且都应按窄增量表述。第一，在预算精确对齐且检查点配对的设计下，快照集成在校准与 OOD 端点系统性劣于独立重启集成——这修正了 Huang 2017 免费午餐叙事在不确定性轴上的适用性，此前未见直接演示（检索截至 2026-10-19）。第二，预算放大规律：固定 k=3 下 DeepEns 对 Single 的 NLL 优势随 B 从 30 增至 120 而从 0.075 增至 0.332，且与单模型验证 NLL 早早触底（中位第 12 epoch）共同出现——一条可检验的规律候选，机制解释自洽但未证。第三，MNIST 饱和边界：单轨迹策略在近饱和任务上无可靠改进，为集成收益的存在性给出了条件（校准余量）。其余内容——集成优于单模型、TS 不能关闭差距、集成在偏移下稳健——分别是三篇以上先例的再确认。

3.3 新增知识是否足够重要、可推广、可复现

三个维度必须分开回答。可复现性是论文最强的维度：逐种子原始记录、位级复现门控（110/110）、公开代码与源数据、预注册统计计划，超过该领域典型标准。重要性居中：预算分配是从业者真实的日常决策，一条可靠的分配规律有实用价值；但快照集成的校准缺陷属于对一项逐渐淡出主流的方法的精确化，受众有限。可推广性是最弱维度：规律只在两种架构、三种灰度图数据与一个小规模 CNN 上测得，k 与 B 的联合行为未测，未触及现代视觉基准。综合：作为以新颖性为门槛的期刊投稿，当前证据组合不足；作为以主张-证据支持为标准的投稿，当前证据组合充分且质量突出。

3.4 共识验证还是未揭示的规律

判定：混合体，但其头牌是共识验证。论文约六成的结果篇幅服务于对已知结论的更严格再确认（四元排序、TS、OOD 稳健性），约四分之一是边界条件与例外（MNIST、CIFAR ECE 未解析、B=30 拉平），约八分之一是真正的窄增量（快照校准缺陷、预算放大规律）。如果把这些比例倒转——以规律和边界条件为主轴、以确认性内容为支撑——同一批数据可以支撑一篇叙事完全不同的论文。这正是方案 A 与方案 B 的分界：A 只重排叙事，B 同时扩充规律的证据面。

3.5 如果我是编辑：当前版本会再次被拒吗

会，且理由与本次拒稿相同。以当前标题与摘要投任何以新颖性为初筛门槛的期刊，我给出约六到七成的再次初筛拒稿概率：模式匹配的输入（标题句式、结果罗列式摘要、自我声明的验证性定位、小规模实验）一个都没有变。支持这一判断的证据已在 3.1 列举。反方向证据同样真实：检查点配对设计在两轮独立检索中未见先例；快照校准缺陷是对已发表主张的实质性修正；预算放大是可检验规律候选；统计与复现标准高于领域典型；负结果与异常种子的报告诚实。因此若论文被送外审，我预期审稿人评价为技术上无懈可击、贡献增量有限，最终分歧将落在重要性而非正确性上。重构定位后（方案 A/B 的改写），初筛拒稿概率我估计降到四到五成，且送审后通过的可能性显著上升——因为那时的头牌主张不再是任何先例的直接重述。

第四章 三个投入水平的研究方案

三个方案共用同一个原则：先明确研究问题与可证伪预测，再决定实验；不通过堆数据集换录用。每个方案按十一个要素给出。三方案对比总表见 4.4。

4.1 方案 A：最小改动（重定位为受控实证研究）

表 4-1 方案 A 要素表

要素	内容
研究问题	在预算精确对齐的受控设置下，四种预算分配策略的校准与 OOD 行为及其边界条件是什么（描述性，不新设假设）
与文献区别	强调检查点配对与预算轴的系统性（表 2-1 第 7、9、10 行的空位）；补引 Kondratyuk 2020
核心假设	无新假设；以既有预注册结论为主张集合
可证伪预测	既有边界条件即预测：MNIST 方向单轨迹无改进；B=30 处 TS 拉平
必要实验	零。仅从现有数据补两项标注为探索性的分析：排名稳定性量化（今日已完成）与验证 NLL 轨迹机制图（数据已在）
对照方法	现有四条件不变
数据集与模型	不变（FMNIST/MNIST/KMNIST/CIFAR-10；MLP/小 CNN）
统计分析计划	不变；新增内容全部标注探索性，不做推断性主张
预期失败条件	目标期刊仍以新颖性拒稿（中等概率）；TMLR 审稿人在兴趣标准下不接受（低到中等概率，含 AI 披露处置风险）
时间与资源	1 至 2 周写作；无计算资源
最大风险	时间沉没于与 v4.1.2 相同的模式匹配；连续同因拒稿记录

4.2 方案 B：中等改动（预算分配规律）

表 4-2 方案 B 要素表

要素	内容
研究问题	固定总预算 B 下，把预算分给多少个成员（k x B/k）使校准最优？最优 k*(B) 如何随 B 移动？NLL-推理成本前沿形状如何？
与文献区别	Kondratyuk 2020 是容量/FLOPs 轴且无校准端点；Baughman 2019 与 cost-of-ensembling 2025 是应用域精度/分位数端点；无人在校准+OOD 端点上做 k x B 扫描并纳入单轨迹策略
核心假设	H1：NLL 最优 k 随 B 增大（预算越大越养得起多样性）；H2：ECE 最优 k 与 NLL 基本一致；H3：Snapshot/SWA 相对 DeepEns 的缺口对 k 不敏感（组合机制而非成员数效应）
可证伪预测	若 NLL(k) 在各 B 下对 k>=2 平坦无结构，或 k*(B) 无内部最优且随 B 递减，则 H1 被证伪；若 DE-SN 缺口随 k 明显变化，则 H3 被证伪
必要实验	FMNIST 补 k=2/8 于 B=30/60/120（k5 于 B60 已有，k3 全有）：8 个新配置 x 10 种子，约 13 小时 CPU；MNIST 与 CIFAR 各补 k=2/5 于 B=60：4 个配置，约 5 小时 CPU
对照方法	每个 (k,B) 格点内四条件全套（Single 不变；快照/权重平均按 k 个快照组织循环）
数据集与模型	不变；CIFAR 仍为小 CNN（规模化留给方案 C 或审稿响应）
统计分析计划	预注册：每个 B 下 {k=2 vs 3, 3 vs 5, 5 vs 8} 的 NLL 对比族（Holm 校正）+ 跨 k 趋势的 Page 型检验；ECE/OOD 为次级；写作前锁存
预期失败条件	平坦 NLL(k)（此时论文降级为任何 k>=2 均可的决策规则——弱化但可发表）；或规律被指与已知边际收益递减文献无实质区别
时间与资源	实验+分析约 1 周；写作 2 至 3 周；总计 4 至 6 周；纯 CPU
最大风险	被审稿人读成超参数扫描而非科学问题；缓解靠预注册假设与决策规则化表述

4.3 方案 C：高投入（校准感知的预算分配算法）

表 4-3 方案 C 要素表

要素	内容
研究问题	能否用训练内信号（验证校准的边际增益、成员间分歧）在线决定何时终止当前成员并重启，使固定预算下的校准优于任何固定 k 分配
与文献区别	自适应集成构造与早停各有文献（集成选择、Hyperband 族），校准目标+预算分配的组合需要一轮专门检索确认空位（实施第一步）
核心假设	H：贪婪校准边际增益分配 >= 任意固定 k（在测得的 (k,B) 格点上）
可证伪预测	配对检验下控制器不劣于最优固定 k 即证伪 H；次级预测：控制器在 B 大时倾向更多成员

要素	内容
必要实验	控制器实现与调参；对照全部固定 k；先小规模后 WRN-16-4/CIFAR-100 验证（需 GPU 数天）
对照方法	全部固定 k 格点 + Single + Snapshot/SWA；消融：只用分歧信号、只用校准信号
数据集与模型	FMNIST（开发）+ CIFAR-100/WRN（可信度）；至少一个现代基准否则不可发表为方法
统计分析计划	控制器 vs 最优固定 k 的配对置换检验（种子配对，10 种子）；多预算重复
预期失败条件	增益不显著（很可能：固定 k=3 已接近饱和的先兆在 k5 数据中可见）；规模化后规律消失
时间与资源	2 至 4 个月；需要 GPU；需先完成一轮新的占位检索
最大风险	方法增量空间拥挤，审稿要求大规模对比，单作者资源难以支撑；失败概率为三方案最高

4.4 三方案对比

表 4-4 方案对比总表

维度	方案 A 重定位	方案 B 分配规律	方案 C 分配算法
新增科学贡献	无（叙事重排）	一条规律 + 决策规则	一个新方法（若成功）
时间	1-2 周	4-6 周	2-4 月
计算	无	纯 CPU 约 18 小时	GPU 数天
失败概率（主观）	中高	中	高
失败时残余价值	零	决策规则 + 边界图	负结果（难发表）
目标期刊层	TMLR / 实证类	TMLR / Machine Learning / Neurocomputing，规律清晰可上探	方法类期刊或会议

第五章 最推荐方案及实施步骤

推荐方案 B。理由有三：它是唯一能在可控成本内把论文头牌从确认性内容换成规律性内容的路径；全部实验复用已通过位级复现门控的现有管线，边际风险低；即使规律平坦，结果仍以决策规则形态可用，失败残余价值最高。以下十步为具体实施清单，每步含完成判据。

表 5-1 方案 B 实施步骤（预计日历 4 至 6 周）

步骤	内容	完成判据
1. 预注册补丁	在 research-docs 新增 addendum-design-kB.md：三假设、对比族、趋势检验、所有格点与种子数，先于任何新数据收集	文档入库并有日期戳
2. 管线确认	核对 run_experiments_v2.py 的 k/budget 参数化路径与快照组织方式（k 个 B/k 循环）；seed0 试跑一组做位级一致性门控	k=3 设置与既有记录位级一致
3. 实验矩阵	FMNIST：(k=2,5,8) x (B=30,120) 加 k=2,8 于 B=60，共 8 配置；MNIST 与 CIFAR 各 (k=2,5) 于 B=60，共 4 配置；全部 10 种子	12 个新 JSONL 齐全，无 NaN
4. 统计分析	按预注册族执行 analyze 扩展：每 B 的 k 对比（Holm）+ 跨 k 趋势 + ECE/OOD 次级	contrasts.csv 全量产出
5. 结果判定	按 4.2 的证伪条件判定 H1/H2/H3；把判定结论写进 addendum（无论方向）	三个假设各有一个明确判定
6. 机制图	用既有 histories 画 val-NLL 轨迹随 B 的触底-恶化图（数据已在，标注探索性）	图与源数据入库
7. 论文重构	新标题与新摘要（见下）；预算放大规律升为主结果之一；确认性内容压缩为稳健性章节；排名稳定性一小节（标注探索性）	v5.0.0 草稿完成
8. 内部审计	复用 v4.1 审计管线：主张-证据矩阵更新、全部新数值独立复算、红线检查（不删除既有边界条件表述）	核验报告全过
9. 投稿包	按目标期刊界面重建（LaTeX 源 + Cover Letter + 贡献声明）；披露政策按期刊逐项处理	包完整且与仓库 release 一致
10. 投稿与记录	提交；把审稿意见与处置逐条归档到 research-docs	提交确认号 + 意见归档

新标题候选（问题式，避免共识句式）：How to spend a fixed training budget: ensemble size, calibration and inference cost；或 The calibration-optimal budget split: how many restarts to train under fixed compute。摘要第一句必须直接陈述未知问题（固定预算下最优成员数未知），第一段末给出 k*(B) 的实测答案。定位段须补引 Kondratyuk et al. 2020 并说明容量轴与时长轴的差别。

第六章 新增实验必要性清单

本章回答两个问题：哪些新实验必须做；以及哪些分析可以从现有数据免费获得。后者的检验已在本次审计完成（标注探索性），结论如下。

6.1 从现有数据可挖的分析（本次审计已完成检验）

表 6-1 现有数据挖掘结论（全部标注为探索性）

候选分析	今日检验结果	处置建议
训练随机性是否改变方法排名	五/六设置中 DeepEns 为 10/10 种子最优（CIFAR 9/10）；FMNIST 四设置成对方向 10/10 一致；翻转仅出现在已记录的两个近平局（MNIST 的 SWA-SG 3/10；CIFAR 的 DE-SN 1/10，异常种子）	推荐入正文一小节：把均值结论升级为逐种子一致性证据（强）
单模型训练时长的校准代价	val-NLL 触底中位 epoch：FMNIST 12（7-14）对 MNIST 46（40-58）；FMNIST 终点 0.476	推荐入正文：预算放大规律的机制图（数据已在 histories）
校准改善与 OOD 改善是否耦合	九个设置-探针内 rho(dECE,dAUROC) 从 -0.73 到 +0.52 方向不一；跨设置混杂主导	不推荐作为主张（负结果）；一句话写入讨论即可
成员质量/多样性种子级规律	组内 rho 在 -0.77 至 +0.77 间不稳定	维持关联性措辞；不作主张
预算-推理成本权衡叙事	k=3/5 两点 + B 三点已能画出雏形	作为方案 B 的引子段落，待 k 扫描补全

6.2 必须新增的实验（仅方案 B 所列）

必须做的只有 k x B 扫描的 12 个新配置（表 5-1 步骤 3），全部 CPU 可完成，无任何新基础设施。判断为必须的依据：k*(B) 是规律主张的最小证据集，且现有 k=3/5 两点无法分解成员质量与多样性两个反向机制（k5 成员更优 0.321 对 0.338 但多样性更低 0.0101 对 0.0150）。

6.3 可选强化（作者资源决定，非必需）

唯一值得考虑的可选强化是把 CIFAR 侧从 k=2/5 的 10 种子扩到一个中等规模基准（如 WRN-16-4 于 CIFAR-100，2 x 10 种子，需 GPU 约两天）：它直接回应可推广性折扣，但会改变论文的规模叙事与时间线，故列为作者决策项而非默认项。

6.4 明确不再做的实验

以下各项被明确排除，理由是它们不改变原创性判断而只增加体量：新增第四个灰度或更多自然图像数据集；把种子数从 10 提到 30（除非某个关键对比的置信区间需要且预注册批准）；批量归一化统计复现实验；CIFAR-10-C 式扰动套件；新增 OOD 探针；任何以寻找显著结果为目的的事后扫描——探索性分析与确认性分析的边界已在预注册文档与本文中固定，新增分析一律标注性质。

第七章 停止规则

为避免无止境的加法，本章给出可判定的停止条件。核心原则：继续的依据是规律的证据质量，不是已有投入。

表 7-1 停止与继续的判定标准

情形	判定	动作
方案 B 的 k*(B) 规律成立（趋势检验显著且方向一致）	继续	完成 v5 论文，投 TMLR 或 Machine Learning；考虑规模化可选强化
NLL(k) 平坦（任何 k>=2 无显著差）	弱继续	以决策规则（k=2 或 3 已足 + 推理成本）完成论文，投实证类期刊；不再追加实验
k*(B) 规律被新检索发现已有等价先例	停止发展	回退方案 A：重定位为受控实证研究，投 TMLR；不再投入新实验
两轮投稿（不同期刊）均以原创性被拒且审稿人未给出具体可行扩展	停止投稿迭代	以 TMLR 为终点通道（一次机会），或归档为预印本；转向新项目
审稿人点名要求规模化验证	条件继续	仅当作者有 GPU 资源且预计两周内可完成时执行 6.3 的可选强化；否则撤回改投
统计红线被触碰（为消警告删除边界条件/异常种子）	禁止	任何情况下不允许；这是论文的最后价值所在

底线声明：若六至八周内未获得可辩护的新规律，正确动作是以方案 A 形态完成一次 TMLR 投稿后停止本论文的迭代，把剩余精力投入下一个研究问题。本论文作为严谨的受控实证研究已有完整价值，不需要通过无限扩展来证明自己。

第八章 下一阶段工作计划

按方案 B 与停止规则，给出六周的执行计划。每周末设判定点：未过判定点则触发第七章对应条款，不自动顺延。

表 8-1 六周执行计划

周次	任务	产出	周末判定点
第 1 周	预注册补丁；管线 k 参数化验证与 seed0 位级门控；启动 FMNIST 8 配置训练	addendum-design-kB.md；8 个进行中配置	seed0 与既有 k=3 记录位级一致
第 2 周	完成全部 12 配置；执行预注册统计分析	新 JSONL 全量 + contrasts 扩展	无 NaN；对比族全部可计算
第 3 周	结果判定（H1/H2/H3）；机制图；与停止规则对照定稿叙事	判定记录 + 图	三假设各有明确判定
第 4 周	论文重构：新标题/摘要/定位；预算规律升主结果；压缩确认性章节	v5.0.0 全文草稿	主张-证据矩阵更新且无未绑定主张

周次	任务	产出	周末判定点
第 5 周	内部审计：新数值独立复算、红线检查、编译检查；投稿包制作	核验报告 + 投稿包	审计全过；投稿包与仓库一致
第 6 周	提交目标期刊；意见与处置归档	提交确认 + 归档	提交完成

第九章 期刊重选判断框架

期刊选择应在完成原创性审计之后做（本报告即是），且只与论文的最终形态绑定：方案 A/B 形态对应实证与严谨优先的通道，方案 C 形态才对应方法创新通道。以下按三类给出，核验状态逐项标注（核验日期 2026-10-19；费用与政策以投稿时官网为准）。

表 9-1 三类期刊框架与核验状态

类别	代表期刊	适配条件	核验状态（2026-10-19）
以主张-证据支持为标准（方案 A/B 首选）	TMLR	论文重定位为受控实证研究；双盲；开放评审	已核验官方录取标准：新颖性非必要、明确避免以不新颖为由拒稿；同时载有全 AI 生成论文难以满足兴趣标准的条款（详见 9.1）
扎实实证比较可发的中等期刊	Machine Learning (Springer)；Neurocomputing (Elsevier)；Neural Computing and Applications (Springer)	需要比 TMLR 更强的规律性结果（方案 B 成功后）	Neurocomputing 范围已核验（欢迎对神经网络与学习系统的理论理解类贡献）；ML/NCA 范围待逐刊核对；三者均为订阅制可免费发表（待投稿时确认）
应用/开放获取通道	IEEE Access；PLOS ONE	以正确性与完整性为准的最终出口	PLOS ONE 以科学严谨性为标准的定位与其官方说明一致（细节待核）；IEEE Access 有 APC（约 1,995 美元量级，以官网现价为准）；两者均应在 TMLR 之后再考虑
方法创新期刊（仅方案 C）	IJMLC 重投；Neural Networks；会议（AISTATS/ICLR）	仅当校准感知分配算法被验证有效且规模化	IJMLC 本次拒稿期刊，重投需实质新贡献；其余需方案 C 完成后再议

9.1 TMLR 特别注意事项

TMLR 是本论文当前形态最匹配的期刊，其官方录取标准（2026-10-19 核验）只有两条：主张是否有准确且令人信服的证据支持；是否有一定受众感兴趣且表达清晰。标准明确写了不应以不够新颖或不够重要为由拒稿，且系统性研究已发表方法的稳健性并给出可操作结论的稿件可以满足兴趣标准——这几乎是为重定位后的本论文写的描述。但有四点必须如实处理。第一，双盲：投稿版需匿名化（仓库链接与致谢处理）。第二，TMLR 是开放评审，所有往来公开。第三，费用：官网未

列出任何发表费（历史上为免费发表、钻石开放获取），投稿时再确认。第四，也是最实质的：其兴趣标准原文载明完全由 AI 生成而人类参与极少的论文不太可能满足该标准。本论文的工作流为作者主导研究设计与核验、大语言模型辅助执行大量代码分析与初稿——作者必须在投稿时按 TMLR 的政策如实陈述这一参与方式并自行判断其披露口径；这既是合规问题也是现实的审稿风险点，本报告不替作者作此决定，但明确提示：隐瞒不是可选项，表述方式由作者决定并承担责任。

结语：对最终问题的明确回答

问题：如果不新增任何实质性科学贡献，仅对现有稿件润色并转投，是否值得？

回答：对绝大多数期刊，不值得。三个理由。其一，拒稿理由是编辑对内容原创性的判断，不是对文字质量的判断；润色不改变初筛模式匹配的任何输入（标题句式、摘要结构、自我定位、实验规模），同样的拒稿信可以预期再次到来。其二，每一轮初筛周期四到十周，连续同因拒稿不产生任何可学习的信号，且多数投稿系统要求申报被拒历史，累计的是记录而非进展。其三，论文的科学价值密度是固定的：把它反复投向以新颖性为门槛的期刊，只是在用时间验证一个已经由本次拒稿给出的答案。

两个例外。例外一是 TMLR：它的录取标准不以新颖性为门槛，本论文以受控实证研究的身份重定位后是合格的候选——但那不是润色，而是重写标题、摘要、定位与贡献结构的重定位工作，且须按其政策如实处理大语言模型参与的披露。例外二是方案 B 失败后的保底场景：若 k 扫描显示平坦，论文以决策规则形态完成一次 TMLR 投稿即停止迭代。

更优路径是方案 B：用约四周时间和纯 CPU 的边际成本，把论文最接近可检验规律的预算放大元素扩成 k*(B) 分配规律加决策规则，使头牌主张从领域共识换成新的经验规律。这既改变初筛的模式匹配结果，也改变送审后的辩论焦点——从它是否重要转向规律是否成立，而后者是这篇论文的强项。

附录 可核验性记录

本报告的每个事实性陈述可由以下材料复核。审计时间：2026-10-19（Asia/Shanghai）。论文版本基线：v4.1.2（仓库 main 分支 1bc7f61，release paper-v4.1.2）。

表 A-1 核验材料索引

材料	位置	用途
全部逐种子原始记录	仓库 results/*.jsonl 与 results/v2|cifar/*.jsonl	本报告第一章全部数值的来源
预注册统计设计	research-docs/research-design.md	确认性与探索性分析的边界
历史数值核验与例外处置	research-docs/number-verification-v4.1.md；claim-evidence-matrix-v4.1.md	241 项核验、9 项例外、主张-证据绑定
定位审计（检索方法与结论）	research-docs/literature-positioning-v4.1.md	表 2-1 的仓库侧证据
本次探索性复核脚本	scripts/audit_explore_v1.py；audit_explore_v2.py（本审计新增）	第一章与表 6-1 的今日复算，可直接重跑
本轮独立检索	学术检索 14 条查询 + 3 篇原文/官方页核读（Kondratyuk 2005.00570；arXiv 2506.04677；TMLR 官网录取标准页），日期 2026-10-19	表 2-1 新增行与第九章政策陈述
快照位级一致性	各 JSONL 记录 shared_member_bit_identical 字段（60/60 为真）	检查点配对设计的事实基础

复算示例（今日执行）：排名一致性由逐种子 NLL 排序直接统计；预算趋势 0.0754/0.2245/0.3317 为 DeepEns-Single 配对差的按种子均值；验证 NLL 触底 epoch 由 histories 字段的逐 epoch val_nll 取 argmin 后取中位数；全部脚本无需修改即可重跑。任何与本报告不一致的复算结果应以原始记录为准并反馈修订。