PREREGISTRATION PLAN

预注册式实验计划：固定预算下的成员数与训练深度分配

v5.0 研究计划（方案 B）：研究问题、假设、网格、统计与停止规则

> 研究项目：固定训练预算下的集成不确定性研究
>
> 登记日期：2026 年 10 月 19 日（本文件即预注册文本）
>
> 执行前置条件：核验报告（Doc 1）与文献缺口判定（Doc 2）已完成
>
> 算力预算：阶段合计 ≈ 12–16 CPU 小时（含条件阶段 S2）

目 录

一、研究问题重构.....

一、研究问题重构.....1

二、既有数据与新增实验的边界声明.....1

三、可证伪假设与失败判据.....2

四、实验网格与可行性核查.....2

五、预算记账规则与成本报告.....2

六、指标与统计分析计划.....2

七、实验网格、消融与阶段设计.....3

7.1 阶段门与停止规则.....3

八、数据完整性与执行承诺.....4

注：本目录由域代码生成。如编辑后页码发生变化，请在目录上右键选择“更新域”以刷新页码。

一、研究问题重构

本计划把论文的核心问题从“哪种集成策略在固定预算下更好”重构为分配问题：在总训练预算 B 固定的条件下，应当训练多少个独立模型（成员数 k）、每个成员训练多长（e=B/k），才能在预测质量、校准与推理成本之间取得合理平衡。原问题的答案（预算分割优于单轨迹）已被本项目与 Ashukha 等的先例共同确立，继续以排序为主张将重复已知结论；而分配问题的内部结构——k 曲线的形状、最优 k 是否随 B 移动、独立重启优势随 (B,k) 的变化、任务饱和度的调节作用——在所查文献内没有系统回答（见交付物二）。

具体研究问题五项。RQ1：固定 B 时，集成条件（DeepEns/Snapshot/SWA）的 NLL、ECE、Brier、准确率随 k 如何变化，是否存在饱和的 k 区间？RQ2：最优成员数 k*(B)（若存在）是否随总预算 B 增长？这等价于检验核验报告 §7 给出的机制假说：成员训练长度 e 的退化与单模型后期过度自信共同决定分配。RQ3：独立重启相对单轨迹（快照）的优势（DeepEns−Snapshot）随 (B,k) 如何变化？RQ4：上述现象是否依赖任务的校准余量（近饱和 MNIST vs 有余量的 FMNIST/CIFAR-10）？RQ5：模型选择规则（最终权重 vs 验证集早停）是否改变“单模型预算越大越差”的基础事实，从而改变分配建议？

二、既有数据与新增实验的边界声明

预注册地位声明：v1/v2/CIFAR 时代的全部记录（含 B30/60/120 × k3 与 B60×k5）在本计划中一律定为探索性/假设生成数据：它们在其原预注册问题（四路比较）下是确认性的，但对新研究问题（k 曲线与 k* 随 B 的变化）而言属于事后分析。为消除版本混合，v5 网格的全部单元（含与旧记录重叠的 k3 与 k5 单元）在同一新环境（torch 2.14.1+cpu，双线程）下重跑，不引用旧记录作为主结果数据；旧记录仅用于跨版本稳健性对照与一致性抽查。本轮已获得一项打印精度的跨版本一致证据（B60 种子 0 单模型 NLL=0.5250）但不作位级结论。

三、可证伪假设与失败判据

全部假设在新数据收集前写下，均给出可操作的失败判据。等效性界值预先固定：NLL 的 δ=0.010 nats，ECE 的 δ=0.005；其依据为：约为核心设置 DeepEns−Single 效应量（0.2245）的 4.5%，约为 DE−SN 差距（0.0465）的 21%，与

种子级标准差（0.002–0.016）同量级——即“小于该界值的差异在本设计的分辨率下不具实质意义”。

表 3-1 预注册假设

假设	内容	失败判据
H1 饱和	固定 B≥60 时，DeepEns 的 NLL 随 k 增大而改善但边际递减；B=120 时 k=5 与 k=8 的差距在等效界内	若 DE(k8) 比 DE(k5) 低超过 δ=0.010（TOST 拒绝等效）或 k 曲线在 k≤2 即饱和，则 H1 修正为反向形状并如实报告
H2 机制/放大	固定每成员训练长度 e ≈ 20 时集成 NLL 基本不随 B 变化；DeepEns−Single 差距随 B 单调扩大且主要由 Single 恶化贡献	若固定 e 的横向比较中集成 NLL 随 B 显著变化，或 B240 外推时趋势中断/反转（相邻预算点 95%CI 重叠或反向），则放弃“放大规律”表述，降格为局部观察
H3 快照差距	DeepEns−Snapshot 差距随 k 增大而收窄（循环末端快照的单成员训练更短、过度自信更轻）	若该差距不随 k 单调减小或在任一 (B,k) 反转为显著正值，则 H3 被推翻
H4 边界	近饱和 MNIST 上分配效应衰减（DE−SG ≤ 0.02），而 CIFAR-10 CNN 上放大	若 MNIST 上效应显著或 CIFAR 上效应缺失，则边界条件表述需修正
H5 温度缩放	逐条件 TS 压缩但不消除 B≥60 的 k 效应与 DE−SG 差距；B30 处趋于拉平	若 TS 后任一 B≥60 预算上最优 k 与其他 k 的差距进入等效界，则如实改写为“TS 可替代”
H6 推理成本	预测平均的延迟/显存/存储随 k 线性增长；给出实测数字	仅描述性，无失败判据，但必须与训练预算分开报告

四、实验网格与可行性核查

可行性规则（代码级证明 + 冒烟实证）：run_experiments_v2.py 的实现要求 B 能被 k 整除。快照条件以 (epoch+1) % (B//k)==0 截取检查点，成员训练长度为 B//k；若 B 不被 k 整除，两者会静默分叉。本轮冒烟实验实证：B=60, k=8 时运行不报错，但成员实际各训 7 epochs（总预算 56≠60）且共享成员位级一致性检查失败（shared_ok=False，因循环长度 7.5 epochs 非整数，第一个快照不在循环末端）——这正是“表面预算公平”的陷阱，故网格严格限定 k | B。此外规定每成员训练长度 e≥6，以保证成员脱离欠拟合状态（FMNIST 验证最优 epoch 中位约 12）。

五、预算记账规则与成本报告

表 5-1 记账规则

成本项	计入训练预算？	说明
优化器更新 epochs（同数据、同批大小、同调度族）	计入	每种子 2B+(k−1)B/k；四条件名义预算各为 B，严格相等

成本项	计入训练预算？	说明
逐 epoch 验证监控前向	不计入（各条件等量）	总数 = 总 epochs，四条件相同
温度缩放拟合（验证集单次前向）	不计入（各条件等量）	逐条件×种子各一次
seed-0 位级校验重跑	不计入	校验性开销，+B/k epochs，另行披露
CIFAR 分片检查点 I/O	不计入	实现性开销，各条件等量；一次性验证过位级等价
推理成本（延迟/显存/存储）	不计入，单独报告	H6：batch=1 与 256 的 CPU 延迟、参数量、k× 存储

六、指标与统计分析计划

分析单位为种子（每个种子贡献每条件每指标一个值），全部对比为种子内配对。主要结局为原始测试 NLL；次要结局为 ECE-15、Brier、准确率、TS-NLL 与 OOD AUROC（MSP，正类=分布内）。每配置报告均值±跨种子标准差并展示全部种子散点。检验分两族：族一为沿用 v4 的五对比族（DE−SG、SN−SG、SWA−SG、DE−SN、SN−SWA，逐 (B,k) 设置内 Holm 校正，精确符号翻转置换检验 n=10 时未校正下限 0.0020、Holm 下限 0.0098）；族二为新增的分配族——同一 B 内 DeepEns(k) 与 DeepEns(k′) 的全部成对差值，逐 B 做 Holm 校正。两族事先声明，族二为本研究的核心推断对象。

等效性与非劣效性的预先规定：任何“某 k 已足够”的主张必须通过 TOST（两个单侧 90% 置信区落在 ±δ 界值内）而非“差异不显著”；对应地，任何不显著结果均不得表述为等效。报告的 P 值与置信区必须同时给出；多重比较处理方式、比较对象与统计单位在每张表注释中声明。对“最优 k 因数据集/预算/指标而异”的情形，预先声明这本身就是合法发现（不存在普适最优解），但任务条件与分配选择的关联只能称为关联。

七、实验网格、消融与阶段设计

表 7-1 v5 实验网格（FMNIST 为主，全部 10 种子）

阶段	设置	新增/重跑	每种子 epochs	估算
S1 主网格	FMNIST B30×{k2,3,5} + B60×{k2,3,5} + B120×{k2,3,5,8}（10 单元全新重跑，含 k3/k5）	10 单元	75/80/84 + 150/160/168 + 300/320/336/345	≈ 20,300 epochs ≈ 5–6 h

阶段	设置	新增/重跑	每种子 epochs	估算
S2 外推（条件启动）	FMNIST B240×{k2,3,5,8}	4 单元	600/640/672/705	≈ 26,200 epochs ≈ 7 h，仅当 G1 通过后执行
S3 迁移	MNIST B120×{k2,5} + CIFAR-10 B60×{k2,5}（CNN）	4 单元	300/336 + 150/168	≈ 1.5 h + ≈ 2 h
A1 选择规则消融	Single 的验证集早停版（B30/60/120 重训并在验证最优 epoch 评测测试集）	3 单元	30/60/120	≈ 0.5 h
A2 推理基准	延迟（batch 1/256、CPU）、参数、显存、k 扫描	脚本	—	<10 min

每 (B,k) 单元仍由 run_experiments_v2.py / run_experiments_cifar.py 执行，四条件同时重跑；冒烟测试已验证 B60×k2 可跑通（76 s/种子含评估，shared_ok=True）与 B60×k8 的静默失配。分片执行协议沿用 --time-budget 断点续跑。

7.1 阶段门与停止规则

表 7-2 阶段门判定

门	通过条件（进入下一阶段）	不通过时
G1（S1 后）	k 曲线形状可归类（单调改善、饱和或平坦）且全部配对方向一致	若 k 效应方向在预算间不一致或方差超出等效界：先扩大种子至 15 再判；仍不清晰则承认无稳定形状并如实报告
G2（S2 后）	B240 延续放大趋势（相邻预算点 CI 不重叠且方向一致）	放弃“预算放大规律”主张，改为局部经验观察
G3（S3 后）	MNIST 衰减 + CIFAR 增强的边界模式复现	修正边界条件表述
全局停止	任一阶段发现设计缺陷（如预算失配、波动崩溃）	停止、修补预注册再续跑，差异全部留档

另设研究方向的停止规则：若 S1 显示单模型 NLL 不再随 B 恶化（放大机制在新数据中消失），或 S1–S3 合并后仅能得到“集成通常优于单模型”级别的已知结论，则按用户的既定原则诚实缩小定位——将论文改写为分配饱和的边界性研究或转向应用型实证期刊，而不是包装原创性。

八、数据完整性与执行承诺

全部配置使用统一种子方案（base=10000+100s，s∈[0,10)；共享首成员约定不变），逐种子原始记录即时落盘 JSONL 并附运行环境版本。任何种子不删除：训练崩溃、发散或异常种子一律保留并在稿件中报告（沿用 CIFAR 种子 8 的先例：崩溃

成员被完整诊断、删一敏感性同时呈现）。新网格中的重启失败按预登记口径计数并报告频率。模型选择规则唯一：最终权重（A1 消融除外，其规则在本计划中预先写明）。全部预注册内容以本文件（日期 2026 年 10 月 19 日）为准；任何偏离——包括增补分析、改动假设或界值——必须在修订日志中显式登记并标注为探索性。分析脚本、原始记录、图源数据与冒烟记录全部公开于同一仓库。

冒烟测试记录（不进入任何分析）：smoke/smoke_fmnist_B60_k2.jsonl（可行配置验证，shared_ok=True）与 smoke/smoke_fmnist_B60_k8.jsonl（不可行配置演示，预算 56≠60、shared_ok=False）。两者仅用于代码验证与可行性规则论证，其数值不得出现在 v5 论文的任何结果表中。