V E R I F I C A T I O N R E P O R T

固定预算集成研究 v4.1.2 稿件全量核验报告

预算公平性、统计红线与数据完整性的独立复核

研究项目：固定训练预算下的集成不确定性研究

核验对象：v4.1.2 稿件（paper-v4.1.2 release，提交 1bc7f61）

核验规模：345 项独立复算 + 241 项历史核验重跑

报告日期：2026 年 10 月 19 日

目 录

一、核验范围、方法与判定规则.....

一、核验范围、方法与判定规则.....1

二、总体结论.....1

三、预算公平性审计（代码级）.....2

3.1 四条件的训练预算记账.....2

3.2 验证集、模型选择与指标一致性.....2

3.3 成本维度与未计入项.....3

四、历史 241 项核验的重审与 9 项例外处置.....3

五、独立复算明细与代表性核对.....3

六、本轮新发现（含未处置项）.....4

七、预算放大效应复核与混淆分析.....5

八、不利结果与异常种子的完整清点.....5

九、对 v5 修订的分级处置清单.....6

注：本目录由域代码生成。如编辑后页码发生变化，请在目录上右键选择“更新域”以刷新页码。

一、核验范围、方法与判定规则

本报告按独立复核原则对 v4.1.2 版稿件（《Deep ensembles outperform snapshot ensembles and weight averaging for calibrated uncertainty under fixed training budgets》，2026 年 10 月 15 日版）执行全量核验。核验对象覆盖：稿件 LaTeX 源文件（v412-work 副本，与公开 release 资产一致）、实验代码（ijmlc-repo，本地 HEAD=1bc7f61=paper-v4.1.2 发布提交，工作树干净）、原始逐种子结果记录（results/ 下 v1、v2 五个设置、CIFAR、SWA-dense 共 8 个 JSONL 文件）以及历史核验脚本与记录。为保证数据链完整，核验前先以 diff 确认 v4-work 冻结副本与 ijmlc-repo 仓库中的结果目录逐字节一致。

核验的独立性体现在三个层面。其一，统计方法全新实现：配对 t 区间、精确符号翻转置换检验（2^{10} 全枚举）、Holm 校正均在本轮重写，不复用 analyze_v2.py 与历史 verify 脚本的任何代码。其二，主张清单直接从 v4.1.2 源文件誊录，覆盖正文与表 1–4 的全部红线数字、正文引用的补充表数值、时间与复现性声明。其三，判定规则明确：复算值必须在发表精度上四舍五入还原发表数字（半 ulp 容差），例如论文写 0.2245，则复算值必须落在 [0.22445, 0.22455] 内方判通过；置信区间端点与 P 值按各自显示位数执行同一规则。任何依赖旧审计报告自述而不对照原始文件的判断，在本轮一律不采信。

核验脚本持久化于 scripts/verify_v50_independent.py，共登记 345 项检查，完整结果（含每项的位置、声明值、复算值、判定）存于 results/verification_v5_independent.json，可重复执行。除脚本化检查外，另有人工核读：LaTeX 全文通读（主张抽取）、实验代码逐行审读（预算记账、种子约定、指标实现、模型选择规则），以及两项冒烟测试（见交付物三）。

二、总体结论

345 项独立检查中 343 项通过、2 项未通过；另有两项时间性声明与一项措辞精度问题以人工判读补充定性。具体而言：表 1（核心设置 60 项）、表 2（核心对比 25 项）、表 3（扩展设置 48 项）、表 4（CIFAR 66 项）的全部均值、标准差、差值置信区间、精确置换 P 值与 Holm 校正 P 值均从原始 JSONL 精确复现；温度缩放部分（20 项）、补充表 S3 引用值（20 项）、OOD 十一组合分类声明（29 项）、机制量与边界条件（8 项）、复现性与完整性（7 项）亦全部通过。两个未通过项均为非

统计性小问题：一是 DE 温度缩放 NLL 的标准误写为 0.0020 而复算为 0.0018（转录级错误）；二是扩展实验“69 分钟”墙钟声明无法从留存记录验证（逐种子记录纯计算量合计 56.4 分钟，队列日志仅存残根）。

数据完整性方面：8 个结果文件均为 10 条记录、种子 0–9 连续、关键指标无 NaN/Inf、无任何被剔除的种子或条件；v1 与 v2 管线在核心设置上的等价性经全种子核对为 280/280 项数值完全一致（10 种子 × 4 条件 × 7 个共同指标），强于论文所记录的“仅 seed 0 的 28 项位级一致”。预算公平性方面：四条件每种子训练量均为 2B+(k−1)B/k epochs 的结构记账成立，验证集仅用于监控与温度缩放、无任何模型选择，指标实现在各管线间共享同一代码路径。总体判断：v4.1.2 的科学内容在其证据边界内是可信的、可复算的；待处置问题全部为编辑级或文档级，不触及任何结论的方向。

三、预算公平性审计（代码级）

3.1 四条件的训练预算记账

对 run_experiments_v2.py 、 common.py 、 run_experiments_cifar.py 与 common_cifar.py 的逐行审读确认如下事实。每个种子 s（base=10000+100s）执行：Single 以 seed base+0 训练 B epochs（单条余弦退火，逐 step 计算）；循环轨迹以同一 seed base+0 训练 B epochs（k 条余弦循环，在 (epoch+1) % (B//k)==0 处深拷贝快照 B 被 k 整除时恰取 k 个循环末端检查点）；DeepEns 的成员 1 即循环轨迹的第一个快照（省一次重复训练），成员 2..k 以独立种子 base+10+i 各训 B/k epochs（各自完整余弦退火）；SWA 取同样 k 个快照的均匀权重平均。因此每种子总训练量为 2B+(k−1)·B/k epochs，四条件的名义预算各为 B epochs，完全相等；seed 0 额外重训一个 B/k 成员做位级一致性校验（校验性开销，不计入任何条件的预算）。

表 3-1 逐种子预算记账（以核心设置 B=60, k=3 为例）

条件	训练内容	epochs	种子	说明
Single	1 × 60（单余弦）	60	base+0	最终权重即结果，无模型选择
Snapshot	1 × 60（3 循环）	60	base+0	取第 20/40/60 epoch 检查点
DeepEns	快照 1 + 2 × 20 独立重启	60	base+0(共享), base+11, base+12	成员级预测平均

条件	训练内容	epochs	种子	说明
SWA	同 Snapshot 的 3 个检查点	60	base+0	权重平均，零额外训练

记账核对： histories 长度 = B × 2（single 与 cyclic 各 B）；新成员 epochs = B//k；核心设置每种子合计 160 epochs，与论文 §3.1 “compute-exact” 声明一致。

3.2 验证集、模型选择与指标一致性

验证集使用方式在代码层面得到确认：每 epoch 结束在 6000 张验证图上计算一次 val NLL，仅写入 history 用于监控曲线，任何条件下均不存在早停、超参选择或基于验证集的检查点挑选；最终权重与循环末端检查点均为确定性规则产生。温度缩放按条件×种子在验证集上拟合单一温度（对集成条件使用对数均值概率作为有效 logits），与论文 §3.4 的声明一致。指标实现方面，NLL/ECE（15 与 10 等宽分箱）/Brier（按类求和）/AUROC（MSP，ID 为正类）/成对 JSD（自然对数）/负熵分数在 v1、v2、CIFAR 三条管线间共享 common.py 的同一函数，逐位一致；熵分数的方向修正（s=Σp·log p，越大越像分布内）有代码注释在案。OOD 探针一律用分布内训练集统计量标准化，匹配部署假设。

3.3 成本维度与未计入项

论文 §3.1 明确区分四个成本维度并将推理成本排除在匹配范围外（预测平均条件每查询需 k 次前向）。本轮审计补充两点：其一，k 个成员的参数存储与推理期显存（k× 参数量）在论文中未显式量化，属表述缺口而非设计缺陷，建议 v5 增补一句量化说明；其二，CIFAR 管线因分片续跑需要逐 epoch 保存检查点，该 I/O 为实现性开销，对所有条件等量存在，不进入预算记账，且一次性验证过“分片→一次跑”位级等价。此外，逐 epoch 验证监控前向传播的总次数等于总训练 epochs，四条件相等，不影响公平性；温度缩放拟合各条件各一次验证集前向，同样相等。

四、历史 241 项核验的重审与 9 项例外处置

对 verify_v41_stage1/2/3.py 的重跑给出与历史记录完全一致的结果：三个脚本分别执行 89、85、67 项检查（合计 241），失败 5、1、3 项（合计 9；其中 MNIST ECE 排序问题同时出现在 stage1 与 stage3，故去重后为 8 个独立问题）。这与 Task 21 记录的“241 项检查、232 项完全复现、9 项例外”自述相符，且本轮为独立重跑，非转引。9 项失败逐一核对当前稿件后的处置状态如下表。

表 4-1 9 项历史例外的当前处置状态

#	例外内容	历史来源	当前 v4.1.2 状态	判定
1–4	表 1 KMNIST 探针 4 个条件的标准差（0.0184/0.0067/0.0131/0.0132）	stage1	已在 v4.1 修正为 0.0116/0.0038/0.0084/0.0112，与本轮复算一致（源文件第 594 行）	已解决
5	MNIST ECE 四元排序主张（v4.0 遗留）	stage1+stage3	已弱化：现文仅报告 DE 显著、SN/SWA 不显著，不再主张四元排序	已解决
6	MNIST NLL 四元排序主张（实际 SWA 均值 0.0741 劣于 Single 0.0724）	stage3	同上，贡献条目已注明“完整排序未在低饱和任务上成立”	已解决
7	CIFAR “其余九个成员平均准确率 0.7257”与复算 0.7249 不符	stage2	仅存在于研究文档，研究文档已标注修正；稿件未受影响（grep=0）	已解决
8	CIFAR “约 3.5 小时”声明与记录符 0.94 小时不符	stage3	源文件第 418 行仍保留原文（见 §6）	未解决
9	ECE-mnist 排序（与 #5 同源，跨两个脚本重复计数）	stage3	同 #5	已解决

结论：9 项例外中 8 项（去重后 7 个独立问题）已在 v4.1→v4.1.2 的修订中解决且与原始数据一致；唯一未处置的是 CIFAR 计时声明，归入下节新发现 N3。这一重审同时说明历史审计的“232 项完全复现”自述本身是可信的——它精确对应本轮独立重跑的失败集合，没有掩盖或美化。

五、独立复算明细与代表性核对

345 项检查按证据族的分布与通过率如下：核心设置表 1（60 项）、表 2（25 项）全部通过；扩展设置表 3（48 项）与 MNIST 直接对比（8 项内含）全部通过；温度缩放族 20 项中 19 项通过（唯一失败为 DE TS-NLL 标准差，见 §6）；补充表 S3 引用值 20 项全部通过；OOD 十一组合 29 项全部通过；CIFAR 表 4 与正文（66+37 项）全部通过；复现性与完整性 7 项全部通过；计时类 4 项中 2 项未通过（见 §6）。代表性核对示例：DeepEns−Single NLL 差值 −0.2245 [−0.2360, −0.2130]，精确置换 P=0.0020，Holm P=0.0098——与论文表 2 完全一致；预算放大三元组 −0.0754 / −0.2245 / −0.3317（B=30/60/120）逐一复现；CIFAR ECE 的 DeepEns−Snapshot 差值 −0.0418 [−0.0845, +0.0008]、未校正 P=0.082 复现，且论文将其表述为“方向一致但未达统计分辨率”的处理是恰当的——该结果未被写成显著差异

几个此前未被脚本化核验、本轮新增的声明也得到确认：核心设置全部 10 个种子在 NLL 上同时优于所有其他策略（逐种子同号）；k 从 3 增至 5 时三个集成条件的均值 NLL 均改善；ECE-10 敏感性分析下核心设置四元排序不变

（0.0702/0.0234/0.0444/0.0517）；OOD 的 SWA 效应区间 [−0.0157, +0.0247] 与论文四舍五入的 −0.016 到 +0.025 一致；Snapshot 仅在 MNIST 反向两个探针上不显著（9/11 显著）；负熵分数下 SWA 区间 −0.015 到 +0.031（含 CIFAR 探针）复现。

六、本轮新发现（含未处置项）

N1（真实错误，P2 级）：源文件第 755 行将 DeepEns 温度缩放 NLL 写为“0.2891 ± 0.0020”，但复算标准差为 0.001761（ddof=1），应为 0.0018。均值 0.2891 正确。历史脚本核验了该族的均值与对比值但未核验此处的 ± 标准差，故成为漏网之鱼。建议 v5 修正。

N2（不可验证声明，P3 级）：论文 §3.3 称扩展设置“约 9000 训练 epochs（69 分钟墙钟时间）”。逐种子记录的纯计算量合计 56.4 分钟；队列日志（queue1/queue2.log）仅存残启动头部而无完成时间戳，无法从留存记录验证 69 分钟。差额 12.6 分钟与分片执行、进程重启开销相当，声明本身可能属实，但不可复核。建议 v5 改为报告记录计算量并注明开销口径，或在新环境重测。

N3（未处置例外，P2 级）：论文 §3.3 称 CIFAR 复制“约 1600 epochs（约 3.5 小时）”。记录的逐种子墙钟合计为 0.94 小时（每种子 130–529 秒），折合约 2.1 秒/epoch；若 1600 epochs 耗时 3.5 小时则每 epoch 需 7.9 秒，与记录相矛盾。需要说明的机制是：CIFAR 运行采用 epoch 级分片续跑，进程被杀后重启时 run_seed 的 t0 会重置，故 wallclock_s 仅覆盖每个种子最后一段连续执行，真实体验时间应高于 0.94 小时；但即便计入分片开销、数据准备与诊断重跑，“1600 epochs ≈ 3.5 小时”作为单位 epoch 耗时声明仍无法成立。建议 v5 同 N2 处置。

N4（措辞精度，P3 级）：源文件第 761 行述 B30 温度缩放后“各集成策略 TS-NLL 跨度仅 0.2986–0.3126”。复算显示四个条件的 TS-NLL 为 Single 0.3126、DeepEns 0.3013、Snapshot 0.2986、SWA 0.3040；即 0.3126 是 Single 的值，三个集成条件的实际跨度为 0.2986–0.3040。原句先说“重新标定使集成策略趋同”再给出含 Single 的全条件跨度，措辞不够精确但数字本身无误。建议改为“集成条件跨度 0.2986–0.3040，含 Single 在内全部条件跨度 0.2986–0.3126”。

N5（正面新证据）：v1↔v2 等价性核对扩展到全部 10 个种子：10 种子 × 4 条件 × 7 个共同指标共 280 项数值完全一致。这强于论文所引用的 seed-0 28 项校验，可在 v5 中作为更强的复现性证据写入。另外，本轮在 torch 2.14.1（新环境，原为 2.14.0）下的冒烟测试中，B60 单模型的种子 0 NLL 在打印精度上与 v1 记录一致

（0.5250），提示跨补丁版本的确定性在打印精度内保持（仅限打印精度证据，不作位级结论）。

七、预算放大效应复核与混淆分析

论文声称的放大三元组经复算无误：DeepEns−Single 的 NLL 差值在 B=30/60/120 时分别为 −0.0754 / −0.2245 / −0.3317。但“放大”由何而来，是 v5 定位的关键，本轮做了如下分解。单模型侧：Single 的 NLL 从 0.3795 → 0.5265 → 0.6672 单调恶化（累计 +0.288），而其准确率平坦（0.8917 / 0.8895 / 0.8885）——典型的训练后期过度自信。集成侧：DeepEns（k=3）的 NLL 为 0.3041 → 0.3020 → 0.3355，前两档基本持平、B120 反而恶化 +0.034；成员均值 NLL 随每成员训练长度 e=B/3 从 10→20→40 epochs 而恶化（0.3205 / 0.3379 / 0.4276）。因此放大效应在数值上几乎全部由 Single 的恶化贡献（约 95% 的差距增长来自分母侧），而非集成变得更好；且在固定 k=3 下，更大的预算对集成自身也是净伤害。

表 7-1 放大效应分解（FMNIST，k=3，n=10）

B	Single NLL	DeepEns NLL	差距	成员 NLL(e)	Single 验证最优 epoch(中位)	Single 准确率
30	0.3795	0.3041	−0.0754	0.3205 (10)	12	0.8917
60	0.5265	0.3020	−0.2245	0.3379 (20)	12	0.8895
120	0.6672	0.3355	−0.3317	0.4276 (40)	11	0.8885

混淆因素逐一排查的结论：其一，学习率调度不存在跨条件偏倚——每成员的余弦退火按其自身长度等比例压缩，Single 为完整长退火，属设计性差异而非混淆；其二，验证集最优 epoch 的中位数在三个预算下稳定于 11–12，说明 Single 的验证损失早已触底，其后的 2.5–10 × 训练全部发生在验证损失回升区，“预算放大”实质是“允许单模型在验证最优之后继续训练的时长随 B 增长”；其三，数据集难度方面，MNIST（近饱和）的验证最优中位数为 45.5（10 个种子介于 40–58），边界条件方向相反，与论文“校准余量”叙事一致；其四，成员质量与多样性的种子级相关在审计中已知不稳定（rho ∈ [−0.77, +0.77]），论文保留关联性措辞是恰当的。

对 v5 的含义（衔接交付物三）：三个预算点不足以支持“普遍规律”的表述；放大效应被视为待验证的经验性假设，其机制假说（“成员训练长度 e 的退化与单模型后期过度自信的拉锯决定最优分配”）导致两个可检验推论：固定 e 时集成 NLL 应基本不随 B 变化，且最优 k 应随 B 增长。预注册计划将把这两点写成可被数据推翻的假设并配好失败判据。

八、不利结果与异常种子的完整清点

按“不删除不利结果”原则，本轮逐一确认以下不利或例外性结果在原始记录中存在、在稿件中如实报告：MNIST 方向 Snapshot 与 SWA 对 Single 无显著改善（P=0.41）且 SWA 均值劣于 Single；SWA 的 OOD 效应在 MNIST 探针 B=120 上显著为负（−0.0157，校正 P=0.012）；B30 下 DeepEns 准确率为四条件最低（0.8905，配对 −0.0012，P=0.018）、Snapshot 取得最优 Brier（0.1562 对 0.1573）；B30 温度缩放后 DeepEns−Snapshot 差值反转为 +0.0026（校正 P=0.045）；k=5 时 Snapshot 准确率名义最高；CIFAR 的 DeepEns−Snapshot ECE 对比未达显著（P=0.082）；CIFAR 种子 8 的一个新重启在首个 epoch 内崩溃至近均匀预测（成员均值准确率 0.515、集成 NLL 0.929、ECE 0.210），该种子被完整保留于全部分析，并附删一敏感性（移除后 DE−SN 的 NLL/ECE 差值为 −0.2075 / −0.0607，均 P=0.0039）与确定性重跑诊断。全部 8 个结果文件均为 10 种子完整记录，无任何剔除。

额外确认：论文对“差异不显著”的表述纪律总体良好——MNIST 边界、CIFAR ECE、SWA 区间均用“未达统计分辨率”“不显著”而非“等效”；唯一需在 v5 严格化的是若 v5 将主张“某成员数已经足够”，必须按预注册计划配等效性界值与 TOST，不能以“不显著”替代。

九、对 v5 修订的分级处置清单

表 9-1 处置清单

级	事项	位置	处置
P2	DE TS-NLL 标准差 0.0020 应为 0.0018	tex 755	直接修正
P2	CIFAR 3.5 小时计时声明与记录 0.94h 不符	tex 417–418	改报记录计算量并注明口径，或重测
P3	扩展实验 69 分钟不可验证（记录 56.4 min）	tex 415–417	同上口径统一
P3	B30 TS 跨度措辞（0.3126 为 Single 值）	tex 761	改写为双跨度表述
P3	k × 参数存储/显存未显式量化	§3.1 成本段	补一句量化说明
正面	v1↔v2 全种子 280/280 一致	§3.6 复现性	以更强表述替换 28 项校验
正面	放大效应分解与 e-退化证据	新增	并入 v5 研究问题与假设（见交付物三）

综合判定：v4.1.2 不存在任何影响科学结论方向的未处置错误；上述清单可在 v5 重写时一次性完成。核验的全部证据（脚本、JSON 结果、冒烟记录）已随本报

告存档，复算入口为 scripts/verify_v50_independent.py，判定规则与容差在脚本头部说明。