S T A G E 1 R E P O R T

S1 主网格执行报告：k 曲线、最优分配与阶段门判定

v5.0 研究计划（方案 B）阶段报告 · 预注册网格 S1 结果与 G1 判定

> 研究项目：固定训练预算下的集成不确定性研究
>
> 执行日期：2026 年 10 月 20 日（S1 完成，G1 通过）
>
> 前置文档：核验报告 Doc 1 · 文献缺口 Doc 2 · 预注册计划 Doc 3
>
> 数据环境：torch 2.14.1+cpu（双线程）· 10 单元 × 10 种子 · 2.30 h

目 录

一、执行摘要.....
二、执行记录与数据完整性.....
三、核心结果：k 曲线与最优分配（RQ1/RQ2）.....
四、放大规律与机制分解（H2/RQ2）.....
五、预注册假设判定（S1 范围）.....
六、温度缩放对最优分配的影响（新知识）.....
七、族一：v4 排序假设在 10 个新设置下的确认.....
八、偏离登记（预注册第八节承诺）.....
九、G1 判定与后续阶段建议.....
十、可核验性.....

注：本目录由域代码生成。如编辑后页码发生变化，请在目录上右键选择“更新域”以刷新页码。

一、执行摘要

G1 阶段门判定：通过。S1 主网格（FMNIST，B∈{30,60,120}×k∈{2,3,5} 加 B120×k8，共 10 单元 × 10 种子，20,180 训练 epochs，实测 2.30 小时）在预注册环境下全部完成。k 曲线在每个预算内呈现稳定且可归类的形状，全部 12 组分配配对的方向一致性为 9–10/10 种子；按预注册表 7-2，S2（B240 外推）获得启动授权。

三项核心发现（均为确认性结果，族二统计，逐 B Holm 校正）：

- 最优成员数 k* 随预算 B 系统移动：B30 时 k*=3（k3 与 k2 差 −0.0024，在 δ=0.010 等效界内；k5 显著劣化 +0.0120）；B60 时 k*∈[3,5]（k5−k3=−0.0046，等效）；B120 时 k*∈[5,8]（k8−k5=−0.0056，等效，TOST 通过）。不存在普适最优 k，但存在跨预算的统一机制：等价的每成员训练长度区间。
- 机制统一规律：DeepEns 的 NLL 由每成员训练长度 e=B/k 决定，呈倒 U 形——e=6 欠拟合（0.3161）、e∈[10,24] 甜蜜区（0.2909–0.3041）、e≥30 恶化（0.3355–0.4157）。三个预算的最优 k 全部落在 e*∈[10,24] 区间，即 k*≈B/18（范围 B/24 至 B/12）。
- 温度缩放改变最优分配：TS 后最优 k 系统性下移一档（B30: k3→k2；B60: k5→k3；B120: k8→k5），因为长成员校准差但判别力强，TS 修复校准后其准确率优势显现。实践含义：部署时可后校准则选更长成员，不可则选更多成员。

预注册假设判定：H1（饱和）支持；H2（放大机制）支持——放大差距 −0.0754/−0.2245/−0.3317 全部 p=0.0020，且 30→120 预算区间的差距增长 112% 由 Single 恶化贡献；H3（快照差距随 k 收窄）按预注册失败判据被推翻（B30×k5 反转为显著正值 +0.0096，p=0.002）；H5（温度缩放）部分支持——B≥60 的 k 效应 TS 后保留，但“B30 趋于拉平”的表述与数据不符，TS 后 B30 的 k 效应仍显著且最优 k 移至 k2。H4 与 H6 分别留待 S3 与 A2。

二、执行记录与数据完整性

执行环境与预注册声明一致：torch 2.14.1+cpu（双线程）、numpy 2.1.3、统一种子方案 base=10000+100s、s∈[0,10)。分片执行协议按预注册沿用 --time-budget 断点续跑，共 23 个执行分片，无中断损失。偏离一项：宿主 Python 由 3.12.14 升至

3.12.15（环境重置所致，torch/numpy 版本与冒烟记录完全一致；该偏离登记于第八节）。

表 2-1 数据完整性核验（scripts/check_s1_integrity.py，六项全过）

检查	结果	说明
I1 种子完整性	10/10 单元 PASS	每单元恰含种子 0–9，无重复、无截断行
I2 共享成员位级一致	PASS	10 个单元的 seed-0 位级校验 shared_ok=True
I3 跨配置 Single 一致	PASS（7/7 对）	同 B 不同 k 的 Single 逐种子位级一致（Single 不依赖 k 的结构性验证）
I4 跨版本对照	PASS（超额）	B60 seed-0 Single NLL v2=0.525029 vs v5=0.525029，跨 torch 2.14.0→2.14.1 达到位级一致，超出预注册承诺的打印精度；DeepEns NLL 亦位级一致（0.303949）
I5 版本戳统一	PASS	全部 100 条记录均为 torch 2.14.1+cpu / numpy 2.1.3
I6 记录完整	PASS	成员级指标在位；总 wallclock 8,273 秒（2.30 h，预算 5–6 h 内）

数据完整性承诺执行情况：无任何种子被删除或替换；本网格未出现训练崩溃或发散种子（逐种子记录见 results/v5/.jsonl，含每种子 wallclock 与全部指标）。*

三、核心结果：k 曲线与最优分配（RQ1/RQ2）

族二（分配族）是本研究的核心推断对象：同一预算 B 内 DeepEns(k) 与 DeepEns(k′) 的全部成对差值，种子内配对，精确符号翻转置换检验，逐 B 做 Holm 校正。主要结局为原始测试 NLL。下表给出全部 12 组对比；等效性按预注册 TOST 判定（双侧 90% 置信区完全落入 ±δ=0.010）。

表 3-1 族二：DeepEns(k′)−DeepEns(k) 配对差（NLL，n=10 种子）

预算	对比	均值差	95% CI	p(Holm)	TOST 等效	方向
B30	k3−k2	−0.0024	[−0.0042, −0.0005]	0.0059	是	1+/9−
B30	k5−k2	+0.0097	[+0.0077, +0.0116]	0.0059	否	10+/0−
B30	k5−k3	+0.0120	[+0.0113, +0.0127]	0.0059	否	10+/0−
B60	k3−k2	−0.0297	[−0.0332, −0.0263]	0.0059	否	0+/10−
B60	k5−k2	−0.0343	[−0.0383, −0.0302]	0.0059	否	0+/10−
B60	k5−k3	−0.0046	[−0.0063, −0.0028]	0.0059	是	1+/9−
B120	k3−k2	−0.0802	[−0.0861, −0.0743]	0.0117	否	0+/10−
B120	k5−k2	−0.1191	[−0.1267, −0.1116]	0.0117	否	0+/10−
B120	k8−k2	−0.1248	[−0.1315, −0.1180]	0.0117	否	0+/10−
B120	k5−k3	−0.0390	[−0.0416, −0.0363]	0.0117	否	0+/10−

预算	对比	均值差	95% CI	p(Holm)	TOST 等效	方向
B120	k8−k3	−0.0446	[−0.0468, −0.0424]	0.0117	否	0+/10−
B120	k8−k5	−0.0056	[−0.0068, −0.0044]	0.0117	是	0+/10−

统计口径：精确符号翻转置换检验（双尾，n=10 时未校正下限 0.0020）；CI 为配对 t 区间；TOST 为两个单侧检验（90% CI 落入 ±0.010 内判定等效）。"统计显著但等效"的组合（如 B30 的 k3−k2 与 B60 的 k5−k3、B120 的 k8−k5）按预注册解释为：差异可检测到，但幅度低于本设计分辨率下的实质意义阈值——这正是等效界值与显著性检验并用的目的。

表 3-2 k 曲线：DeepEns 平均 NLL（±跨种子标准差）与每成员长度 e=B/k

预算 B	k=2	k=3	k=5	k=8	最优 k*(等效区间)
B30	0.3065±0.0026	0.3041±0.0014	0.3161±0.0010	—	k*=3（k2–k3）
B60	0.3317±0.0049	0.3020±0.0019	0.2974±0.0015	—	k*∈[3,5]
B120	0.4157±0.0097	0.3355±0.0033	0.2965±0.0023	0.2909±0.0012	k*∈[5,8]
e=B/k	15/30/60	10/20/40	6/12/24	15	—

读法与结论：（1）B30 的 k 曲线为倒 U 形（k3 峰值，k5 落入欠拟合区）；B60 与 B120 为单调改善且边际递减（B120 的 k5→k8 增益 −0.0056 进入等效界）。（2）固定 k 跨 B 的纵向读法揭示机制：k=2 时 e=15/30/60 对应 0.3065/0.3317/0.4157——长成员持续恶化；k=5 时 e=6/12/24 对应 0.3161/0.2974/0.2965——e=6 欠拟合、e≥12 进入甜区；k=3 时 e=10/20/40 对应 0.3041/0.3020/0.3355——e≤20 稳定、e=40 恶化。（3）合并三点：DeepEns NLL 是 e 的倒 U 函数，甜区 e∈[10,24]；三个预算的最优 k 全部使 e 落入该区间，故 k*(B)≈B/18，等效区间 [B/24, B/12]。

四、放大规律与机制分解（H2/RQ2）

表 4-1 DeepEns−Single 差距随预算的放大（k=3，n=10 配对）

预算	DE−SG 差距	95% CI	p（置换）	Single NLL	DE NLL	成员 NLL
B30	−0.0754	[−0.0809, −0.0699]	0.0020	0.3795	0.3041	0.3205
B60	−0.2245	[−0.2360, −0.2130]	0.0020	0.5265	0.3020	0.3379
B120	−0.3317	[−0.3416, −0.3219]	0.0020	0.6672	0.3355	0.4276

三个差距的配对置换检验均为可达下限 p=0.0020（十种子同号）。机制分解（预注册 RQ2 假说）：30→120 区间差距共增长 0.2562 nats，其中 Single 恶化贡献 0.2877 nats（112%），DeepEns(k3) 自身变化 +0.0314（−12%，即 DE 轻微恶化反而吸收了部分差距）；30→60 区间 Single 贡献份额 98.6%，60→120 区间 131%（DE

在该区间由 0.3020 微升至 0.3355）。结论与预注册机制假说一致：放大的第一驱动力是单模型随训练时长恶化（过度自信），集成成员在 e≤24 时基本免疫该恶化。

“固定 e 时集成 NLL 基本不随 B 变化”的检验存在网格限制：S1 网格内唯一固定 e 的跨预算对是 e=15（B30×k2 vs B120×k8），其差 −0.0156 超出 δ=0.010 且 TOST 拒绝等效——但该对同时改变了成员数（2 vs 8），无法分离 e 效应与 k 效应，只能作为受混杂的探索性证据登记。支持“固定 e 稳定”的宽松证据：e∈[12,24] 邻近带内的 DE NLL 变化不超过 0.011（0.2909–0.3020）。S2 的 B240×k8（e=30）与 B240×k12（若加跑）可提供更干净的固定 e 对照；当前按预注册口径，H2 的“固定 e”子句降格为带证据的近似表述。

五、预注册假设判定（S1 范围）

表 5-1 假设判定对照（判据原文见预注册计划表 3-1）

假设	S1 数据	判定
H1 饱和：B≥60 时 DE 的 NLL 随 k 改善但边际递减；B120 时 k5 与 k8 差距在等效界内	B60: k3→k5 增益 −0.0046（等效）；B120: k5→k8 增益 −0.0056（等效，TOST CI90 [−0.0066, −0.0046]）；k 曲线未在 k≤2 饱和	支持
H2 放大：DE−SG 差距随 B 单调扩大且主要由 Single 恶化贡献	−0.0754→−0.2245→−0.3317，全 p=0.0020；Single 贡献份额 99–131%；“固定 e≈20”子句受网格限制降格为近似（见第四节）	支持（一子句降格）
H3 快照差距：DE−SN 差距随 k 增大收窄	B30: −0.0170→−0.0083→+0.0096（k5 处反转为显著正值，p=0.002）；B120: k2→k3 平坦（−0.1034→−0.1034）	推翻（按预注册失败判据如实报告）
H5 温度缩放：TS 压缩但不消除 B≥60 的 k 效应与 DE−SG 差距；B30 趋于拉平	TS 后 DE−SG(k3): −0.0114/−0.0434/−0.0567（全 p=0.0020，保留）；B120 的 k5−k2=−0.0266 仍显著；但 TS 后 B30 的 k 效应仍显著且最优 k 移至 k2（k3−k2=+0.0043, p=0.0059）——“拉平”表述不符	部分支持（后半句修正）
H4 边界（MNIST 衰减/CIFAR 放大）	S1 未涉及（S3 范围）	待 S3
H6 推理成本	S1 未涉及（A2 范围）	待 A2

H3 推翻的附带发现具有独立价值：当每成员训练长度被压到 e=6 时，独立重启的 DeepEns 反而显著差于快照集成（B30×k5：DE−SN=+0.0096，p=0.002）。机制解释（探索性）：循环末端快照虽同样只训练 6 epochs，但它位于完整 cosine 退火循环的末端（学习率已降至 0），而独立成员的 6-epoch 单循环同样有退火——两者差异更可能来自数据顺序与初始化的多样性损失，及欠拟合成员的校准缺陷被平均放大。

该发现写入论文时须保持探索性定位（成员级 JSD：B30k5 为 0.0068，低于 B60k5 的 0.0101 与 B120k5 的 0.0174，支持多样性不足解释）。

六、温度缩放对最优分配的影响（新知识）

表 6-1 TS 后的 k 曲线（DeepEns TS-NLL 均值）与 raw 最优对照

预算	k=2	k=3	k=5	k=8	raw 最优 k	TS 后最优 k
B30	0.2969	0.3013	0.3159	—	k3	k2
B60	0.2955	0.2891	0.2942	—	k3/k5	k3
B120	0.3098	0.2917	0.2831	0.2865	k5/k8	k5

TS 后的分配族（逐 B Holm）：B120 的 k5−k2=−0.0266 与 k5−k3=−0.0086 仍显著，k8−k5=+0.0033 反转为显著正值；B60 的 k5−k2=−0.0013 不再显著而 k3−k5=+0.0050 显著。系统模式：TS 后最优 k 比 raw 最优 k 低一档，且 TS 后各预算间的绝对差异收窄（B120 最优 0.2831 vs B30 最优 0.2969，跨预算差距 0.014，小于 raw 口径的 0.013 但形状不同）。实践规则（探索性归纳，写入论文时保持该定位）：若部署环境允许在验证集上做温度后校准，应选择更长成员（更少 k）以换取判别力；若不允许，应选择更多成员以换取原生校准。该规则的多指标一致性（ECE、Brier、AUROC 口径的 k* 是否同向移动）留待全量表格核验。

七、族一：v4 排序假设在 10 个新设置下的确认

族一沿用 v4 的五对比族（DE−SG、SN−SG、SWA−SG、DE−SN、SN−SWA），逐 (B,k) 设置内 Holm 校正。S1 的 10 个设置 × 5 对比 = 50 组检验全部显著（p_holm=0.0098，全部 10/10 种子同号），v4 的条件排序 DeepEns < Snapshot < SWA < Single 在扩大的网格上完整复现；唯一例外仍是 B30×k5 的 DE−SN 方向（+0.0096，快照反超，与 H3 推翻同源）。该族在新数据中的全面确认意味着 v5 论文可以把四条件排序作为稳定背景陈述，而将推断重心放在族二（分配结构）上——这正是与 v4 论文的差异化定位。

八、偏离登记（预注册第八节承诺）

编号	偏离	处置
D1	宿主 Python 3.12.14→3.12.15（会话环境重置；torch 2.14.1+cpu 与 numpy 2.1.3 与冒烟记录完全一致）	登记；跨版本位级对照（I4）证明数值路径未受影响

编号	偏离	处置
D2	H2“固定 e≈20”子句在 S1 网格内无同 k 跨 B 对照；唯一固定 e 对（e=15）受成员数混杂	降格为近似表述（e∈[12,24] 带证据）；S2 可提供补充对照
D3	B30 的 k 曲线形状为倒 U（k3 峰值），超出 G1 预列形状类型（单调改善/饱和/平坦）	按诚实原则扩展归类登记：倒 U 为稳定形状（方向 9–10/10），G1 的实质判据（形状稳定+方向一致）满足
D4	H5 后半句“B30 处趋于拉平”与数据不符（TS 后 B30 的 k 效应仍显著且最优 k 移至 k2）	按预注册失败判据修正表述；TS 后分配变化作为新发现报告（第六节）
D5	实际 wallclock 2.30 h 显著低于估算 5–6 h（CPU 性能差异）	登记；预算内完成，无处置需要

九、G1 判定与后续阶段建议

G1 判定（预注册表 7-2）：通过。（1）k 曲线形状可归类：B60 单调改善（k≥3 后进入等效平台）、B120 单调改善（k≥5 后进入等效平台）、B30 为稳定倒 U（D3 登记）。（2）全部配对方向一致：12 组分配配对的方向一致性为 9–10/10 种子，无方向混乱。（3）方差未超出等效界：全部 CI 宽度 0.002–0.018，与预注册分辨率一致。三项条件满足，S2 获得启动授权；无需扩种子至 15。

表 9-1 后续阶段建议（按预注册网格）

阶段	内容	算力估计	启动条件	建议
S2 外推	FMNIST B240×{k2,3,5,8}	≈3–4 h（新 CPU 实测口径）	G1 通过（已满足）	启动；G2 检验放大外推与 e>24 的恶化预测（B240k8 e=30 应劣于 B120 甜区）
S3 迁移	MNIST B120×{k2,5} + CIFAR-10 B60×{k2,5}	≈1 h + ≈2 h	无前置门	启动；H4 边界判定（MNIST 衰减/CIFAR 放大）
A1 消融	Single 验证集早停版 B30/60/120	≈0.5 h	无前置门	启动；RQ5（选择规则是否改变分配建议）
A2 基准	推理延迟/参数/存储 k 扫描	<10 min	无前置门	启动；H6

全局停止规则核验：S1 未发现设计缺陷（预算记账经 I3 结构性验证）、无波动崩溃、放大机制在新数据中未消失、且 S1 单独已产出超出“集成优于单模型”已知结论的分配结构知识——停止规则的三个触发条件均未命中，研究方向按预注册继续。

十、可核验性

- 原始记录：ijmlc-repo/results/v5/experiment_v5_fmnist_B{30,60,120}_k{2,3,5,8}.jsonl（10 文件，100 条逐种子记录，含版本戳、wallclock、逐条件全指标、TS 拟合值、可靠性图分箱与成员级指标）
- 分析输出：results/v5/analysis_v5.json（全统计）、summary_v5.csv（70 行摘要）、contrasts_v5.csv（族一 50 行 + 族二 12 行）
- 脚本：scripts/run_s1_driver.py（分片驱动）、scripts/check_s1_integrity.py（I1–I6）、scripts/analyze_v5.py（预注册统计，独立于 v2 实现）
- 复现命令：python scripts/run_s1_driver.py 560（断点续跑至 ALL_S1_CELLS_DONE）；python scripts/check_s1_integrity.py；python scripts/analyze_v5.py
- 本报告数值与 analysis_v5.json 一一对应；冒烟记录（smoke/）按预注册不进入任何结果