S T A G E 2 R E P O R T

S2 外推网格执行报告：B240 结果与 G2 阶段门判定

v5.0 研究计划（方案 B）阶段报告 · 预注册网格 S2 结果与假设判定更新

研究项目：固定训练预算下的集成不确定性研究

执行日期：2026 年 10 月 20 日（S2 完成，G2 通过，附形状修正 D6）

前置文档：核验报告 Doc 1 · 文献缺口 Doc 2 · 预注册计划 Doc 3 · S1 报告 Doc 4

数据环境：torch 2.14.1+cpu（双线程）· S2 4 单元 × 10 种子 · 3.06 h

目 录

一、执行摘要.....
二、执行记录与数据完整性.....
三、G2 阶段门判定与放大规律的形状修正.....
四、k 曲线外推：k* 上移与未饱和（H1 更新）.....
五、e 甜区的完整图景（机制汇总）.....
六、温度缩放的条件性与快照差距（H5/H3 更新）.....
七、预注册假设判定更新（S1+S2 合并口径）.....
八、偏离登记（S2 新增）.....
九、S3 启动判定与后续计划.....
十、可核验性.....

注：本目录由域代码生成。如编辑后页码发生变化，请在目录上右键选择“更新域”以刷新页码。

一、执行摘要

G2 阶段门判定：通过（字面判据），附形状修正。S2 外推网格（FMNIST，B=240×k∈{2,3,5,8}，4 单元 × 10 种子，约 26,322 训练 epochs，实测 3.06 小时）在预注册环境下全部完成，六项数据完整性核验全部通过。G2 的两项字面判据——相邻预算点 95% CI 不重叠（30–60、60–120、120–240 三对全部满足）与方向一致（四点全部为负）——均满足；但差距的均值序列不再单调扩大（B120 峰值 −0.3317 → B240 收窄至 −0.2465），预注册 H2 的“单调扩大”表述按失败判据的操作化定义（CI 重叠或反向）未触发降格，须按诚实原则修正为非单调形状并登记偏离 D6。

S2 的五项核心发现：

- 放大效应非单调，峰值在 B120：DE−SG(k3) 差距序列 −0.0754 → −0.2245 → −0.3317 → −0.2465。收窄的机制分解干净：120→240 区间 Single 恶化贡献份额仅 12.6%（0.3795→0.5265→0.6672→0.6564，B240 处单模型 NLL 饱和甚至微降），而固定 k=3 的 DeepEns 成员训练长度 e=80 深度超出甜区，成员 NLL 0.4276→0.5982，集成 0.3355→0.4099。放大规律被重新刻画为条件命题：当单模型仍在恶化且分配保持在甜区内时成立。
- k* 随预算上移的规律在外推端更强：B240 处 k5 与 k8 的差距 −0.0355 远超等效界（TOST 拒绝等效，CI90 [−0.0394, −0.0315]），k 曲线在 k=8 尚未饱和；对照 B120 处 k5–k8 差距 −0.0056（等效）。k*(B) 序列：B30→3，B60→[3,5]，B120→[5,8]，B240→≥8（未饱和），全部配对方向一致性 10/10 种子。
- e 甜区的完整倒 U 图景：B240 网格补齐了 e 的高端——e=48（k5，0.3298）与 e=80（k3，0.4099）、e=120（k2，0.4931）逐级恶化；e=30（k8，0.2943）为 B240 网格内最优。跨预算合并后甜区边界收敛为 e∈[10,30]（B120k8 的 e=15 为全网格最低 0.2909），与 S1 的 e∈[10,24] 推断一致且右边界略外移。
- 温度缩放的分配规则被条件化：S1 发现的“TS 后最优 k 下移一档”（B30: 3→2；B60: 5→3；B120: 8→5）在 B240 处不再成立——TS 后 k8 仍最优（0.2782 < k5 的 0.2886）。机制：B240k5 的 e=48 已超出甜区，成员的功能性缺陷（判别力损失）无法靠温度修复；TS 只能重标定置信度尺度。实践规则的修正表述：TS 可替代“更多成员换原生校准”当且仅当成员训练长度处于甜区内。

- 快照差距（H3）在 B240 呈非单调形状：DE−SN 差距 k2 −0.1054 → k3 −0.1426 → k5 −0.1418 → k8 −0.1177（B120 为单调收窄 −0.1034→−0.0551）。机制（探索性）：B240k8 的快照成员 NLL 0.5680 显著差于同 e 的独立成员 0.3777——循环内快照继承前一循环的过拟合权重，其恶化速度超过独立重启；成员质量劣势（+0.19）超过其轨迹多样性的微弱优势（JSD 0.0135 vs 独立 0.0208）。

对论文定位的影响：v5 的核心贡献从“k×B 分配规律”升级为“预算分配的完整相图”——三条机制曲线（单模型恶化、成员甜区、集成规模收益）共同决定最优分配，且各有失效边界。B240 点位的价值恰在于三个机制中两个出现转折（单模型饱和、固定 k 的甜区违反），使规律从经验拟合提升为有边界条件的可检验命题。

二、执行记录与数据完整性

执行环境与 S1 完全一致：torch 2.14.1+cpu（双线程）、numpy 2.1.3、统一种子方案 base=10000+100s、s∈[0,10)。分片协议沿用 --time-budget 断点续跑；因后台进程会被宿主环境终止（S1 已验证），全部 30 个分片以前台方式执行。发生三次执行层事件，均未造成数据损失：(a) 两次会话级中断（分片被取消，已完成种子已落盘，重跑自动跳过）；(b) 一次 600 秒硬超时的静默失败（子进程被杀且无输出、该种子未写入，重试后正常完成，279 秒）——事件本身不构成数据完整性风险，因为写入以逐种子追加完成，截断行会被断点逻辑忽略，且最终由 I1 种子完整性校验兜底。

表 2-1 S2 数据完整性核验（scripts/check_s2_integrity.py，六项全过）

检查	结果	说明
I1 种子完整性	4/4 单元 PASS	每单元恰含种子 0–9，无重复、无截断行
I2 共享成员位级一致	PASS	4 个单元 seed-0 位级校验 shared_ok=True；此检查同时是 k|B 整除性的结构性验证（B60k8 冒烟失败即表现为 shared_ok=False）
I3 跨配置 Single 一致	PASS（3/3 对）	B240 内不同 k 的 Single 逐种子位级一致（k2 基准 vs k3/k5/k8），结构性预算公平验证
I4 配置戳	PASS	全部 40 条记录 budget=240、k 与文件名一致、id=fmnist、OOD 探针 [mnist, kmnist]
I5 版本戳统一	PASS	全部记录与 S1 戳完全一致（torch 2.14.1+cpu / numpy 2.1.3），S1+S2 可合并分析
I6 记录完整	PASS	成员级指标在位；总 wallclock 11,032 秒（3.06 h，预算 3–4 h 内）

数据完整性承诺执行情况：无任何种子被删除或替换；B240 未出现训练崩溃或发散种子。逐种子记录（含每种子 wallclock、全部指标、TS 拟合值与可靠性分箱）见 results/v5/experiment_v5_fmnist_B240_k{2,3,5,8}.jsonl。

三、G2 阶段门判定与放大规律的形状修正

预注册 G2 判据（表 7-2）：B240 延续放大趋势，操作化为“相邻预算点 95%CI 不重叠且方向一致”。k=3 锚点（四个预算全部覆盖）的四点差距如下表。

表 3-1 DeepEns−Single 差距的四预算序列（k=3 锚点，n=10 配对）

预算	DE−SG 差距	95% CI	p（置换）	相邻 CI 分离	方向
B30	−0.0754	[−0.0809, −0.0699]	0.0020	—	10/10 负
B60	−0.2245	[−0.2360, −0.2130]	0.0020	30–60：分离	10/10 负
B120	−0.3317	[−0.3416, −0.3219]	0.0020	60–120：分离	10/10 负
B240	−0.2465	[−0.2723, −0.2208]	0.0020	120–240：分离	10/10 负

字面判据：通过。三对相邻预算点的 95%CI 全部不重叠，四点方向全部一致（每点 10/10 种子同号），未触发预注册失败条款（“相邻预算点 95%CI 重叠或反向”）。按表 7-2，S3 获得启动授权。

形状修正（偏离 D6，诚实处置）：差距均值序列非单调——B120 达峰值 −0.3317 后，B240 收窄至 −0.2465（收窄幅度 0.0852 nats，超等效界 8 倍）。预注册 H2 主张“差距随 B 单调扩大”中的“单调”一词不再被数据支持；由于操作化失败判据（CI 重叠/反向）未被触发，放大规律不降格为“局部经验观察”，但表述必须修正为条件形式：放大在“单模型持续恶化 × 分配处于甜区”双条件下成立，B240 处两个条件分别失效（见下节机制分解）。这一修正使规律更精确而非更弱：单调拟合四点的残差为 +0.085，条件化表述的残差为零。

表 3-2 差距变动的机制分解（k=3 锚点；Single 恶化份额 = ΔSingle / Δ 差距）

区间	差距变动	Single 变动	DE(k3) 变动	Single 恶化份额	区间主导机制
30→60	+0.1491 扩大	+0.1470	−0.0021	98.6%	单模型恶化主导
60→120	+0.1072 扩大	+0.1407	+0.0335	131%	单模型恶化 + DE 轻微恶化
120→240	−0.0852 收窄	−0.0108（饱和）	+0.0744（e=80 超甜区）	12.6%	DE 成员质量恶化主导
30→240 总计	+0.1711	+0.2769	+0.1058	162%	两机制部分抵消

分解的证据链完整：Single 的 NLL 在 B30→B120 区间恶化 0.2877 nats 而 acc 保持平坦（0.8917→0.8885→0.8896，B240 处 0.8896）——恶化全部来自置信度校准（ECE 0.0493→0.0814，B240 处 0.0807 平台），这是过度自信型恶化的签名；B240 处该机制饱和（NLL 0.6672→0.6564 微降，种子间标准差由 0.0142 增至 0.0296）。同时固定 k=3 的 DE 成员 e 由 40 增至 80，成员 NLL 0.4276→0.5982，集成 NLL 0.3355→0.4099——成员质量超出甜区后的恶化主导了差距收窄。两条机制曲线在 B240 的行为均由预注册的 e 甜区假说预测（B120k3 的 e=40 已在 S1 显示恶化端起点 0.4276），故收窄本身是甜区机制的确认性证据，而非意外。

四、k 曲线外推：k* 上移与未饱和（H1 更新）

表 4-1 族二（B240）：DeepEns(k′)−DeepEns(k) 配对差（NLL，n=10 种子，逐 B Holm）

预算	对比	均值差	95% CI	p(Holm)	TOST 等效	方向
B240	k3−k2	−0.0832	[−0.0911, −0.0754]	0.0117	否	0+/10−
B240	k5−k2	−0.1634	[−0.1692, −0.1575]	0.0117	否	0+/10−
B240	k8−k2	−0.1988	[−0.2070, −0.1906]	0.0117	否	0+/10−
B240	k5−k3	−0.0801	[−0.0863, −0.0740]	0.0117	否	0+/10−
B240	k8−k3	−0.1156	[−0.1213, −0.1099]	0.0117	否	0+/10−
B240	k8−k5	−0.0355	[−0.0404, −0.0305]	0.0117	否	0+/10−

B240 的六组配对全部显著且方向 10/10 一致，没有任何一对进入等效界——这是四个预算中分配效应最强的一档。与 B120 的对照显示 k 曲线右端的形状变化：B120 处 k5→k8 增益 −0.0056（等效，边际递减），B240 处同样两档的增益 −0.0355（七倍于等效界，TOST 拒绝等效）。原因不是集成规模收益本身增强了，而是 k 曲线的位置整体右移：B240 的“劣区”（e>30）覆盖了更多 k 档位，使每增加一个成员（同时缩短每成员长度）的边际收益同时包含“更多样化”与“逃离劣区”两部分。

表 4-2 k 曲线四预算全景（DeepEns 平均 NLL；括号内为 e=B/k）

预算 B	k=2	k=3	k=5	k=8	最优 k*（等效区间）
B30	0.3065 (e15)	0.3041 (e10)	0.3161 (e6)	—	k*=3（k2–k3）
B60	0.3317 (e30)	0.3020 (e20)	0.2974 (e12)	—	k*∈[3,5]
B120	0.4157 (e60)	0.3355 (e40)	0.2965 (e24)	0.2909 (e15)	k*∈[5,8]
B240	0.4931 (e120)	0.4099 (e80)	0.3298 (e48)	0.2943 (e30)	k*≥8（未饱和）

k*(B) 的移动规律在四个预算点完整成立且外推端增强：3 → [3,5] → [5,8] → ≥8。S1 归纳的机制表述 k*≈B/18（等效区间 [B/24, B/12]）在 B240 给出 k*∈[10, 20]——网格上限 k=8 落在该区间左侧，与“k8 仍未饱和”的观测一致。注意该预测同时

意味着 B240 的真实最优 k 可能在 10–20 之间、超出本网格，这构成 v5 论文的一个明确的边界声明（网格未覆盖 k>8），也提示若审稿人质疑可加跑 B240k12（e=20，恰落入甜区中心）作为单点验证——该加跑不在预注册网格内，须作为探索性扩展另行登记。

五、e 甜区的完整图景（机制汇总）

S1 依据 B30–B120 归纳的每成员训练长度甜区 e∈[10,24] 在 S2 得到两侧边界的更精确刻画。固定 e 的跨预算对照（k 混杂，探索性）与单预算内 e 扫描合并如下。

表 5-1 DeepEns NLL 作为每成员训练长度 e 的函数（全部 14 单元）

e 区段	证据点（B, k, DE NLL）	判读
e=6（欠拟合端）	B30k5 0.3161	成员欠拟合，集成受累
e∈[10,30]（甜区）	B30k3 0.3041 · B60k5 0.2974 · B60k3 0.3020 · B120k8 0.2909 · B120k5 0.2965 · B240k8 0.2943	全部落在 0.29–0.31 窄带内，与预算无关（S1 的核心机制）
e=40–48（恶化起点）	B120k3 0.3355 · B240k5 0.3298	超出甜区右边界，恶化 0.03–0.04
e=60–120（深度恶化）	B120k2 0.4157 · B240k3 0.4099 · B240k2 0.4931	成员过度自信主导；e=120 时集成 0.4931 接近 Single 水平

固定 e 的跨预算对的更新（含 S2 新增）：e=15：B30k2 0.3065 vs B120k8 0.2909（Δ=0.0156，k 混杂 2 vs 8）；e=30：B60k2 0.3317 vs B240k8 0.2943（Δ=0.0374，k 混杂 2 vs 8，TOST 拒绝等效 p=1.000）。两对一致显示同 e 下大 k（大 B）组合更优说明甜区不是 e 的一元函数——集成规模有独立的正向贡献。e 的一元性上界由此可量化：固定 e 时跨预算变化 ≤0.037（探索性，混杂未分离）。成员级证据支持双因素解释：B240k2 成员 NLL 0.6685 ≈ Single 0.6564（e=120 的成员与 e=240 的单模型同深度过拟合），而 B240k8 成员 NLL 0.3777 仅比 B120k8 成员 0.3245 高 0.053——k 曲线的本质是成员质量曲线，由 e 主导、由集成平均二阶修正。

六、温度缩放的条件性与快照差距（H5/H3 更新）

表 6-1 TS 前后的最优 k 对照（四预算全景）

预算	raw k 曲线（k2/k3/k5/k8）	TS 后 k 曲线	raw 最优	TS 最优	下移？
B30	0.3065/0.3041/0.3161/—	0.2969/0.3013/0.3159/—	k3	k2	是（一档）
B60	0.3317/0.3020/0.2974/—	0.2955/0.2891/0.2942/—	k5	k3	是（一档）

预算	raw k 曲线（k2/k3/k5/k8）	TS 后 k 曲线	raw 最优	TS 最优	下移？
B120	0.4157/0.3355/0.2965/0.2909	0.3098/0.2917/0.2831/0.2865	k8	k5	是（一档）
B240	0.4931/0.4099/0.3298/0.2943	0.3199/0.3060/0.2886/0.2782	k8	k8	否（不变）

S1 的“TS 后最优 k 下移一档”规则在 B240 失效（偏离 D7）。失效的机制值得在论文中单独成段：B240k5 的 TS 后 NLL 0.2886 仍比 k8 的 0.2782 高 0.010——恰在等效界上。观察 B120k5（e=24，甜区内）TS 后反超 k8 成为最优，而 B240k5（e=48，甜区外）TS 后仍被 k8 压制：TS 修复的是置信度温度，不能修复超长成员的判别力损失（acc：B240k5 0.8996 vs k8 0.9004，差距虽小但 NLL 惩罚置信度错置）。规则的条件形式：成员长度在甜区内时，TS 可替代约一档的集成规模；超出甜区后不可替代。这一条件化本身是 e 甜区机制的第三个独立证据来源（第一个是 k 曲线形状，第二个是放大分解，第三个是 TS 修复边界）。

H3（快照差距随 k 收窄）在 B240 的形状：k2 −0.1054、k3 −0.1426、k5 −0.1418、k8 −0.1177——非单调，在 k3–k5 处最深、k8 回升。S1 已按预注册失败判据推翻 H3（B30k5 反转），B240 增加的信息是快照劣势在大预算下不会消失（四档全部 p=0.002，10/10 同号）：循环末端快照的成员质量（B240k8 成员 NLL 0.5680）显著差于同长度的独立成员（0.3777），因为快照继承前一循环末端的过拟合权重状态而非从初始化重新退火。快照集成的成员间 JSD（0.0135）低于独立重启（0.0208），多样性同时处于劣势。两劣势叠加使 Snapshot 在全部 14 个设置中无一进入最优条件。

七、预注册假设判定更新（S1+S2 合并口径）

表 7-1 假设判定对照（判据原文见预注册计划表 3-1；本表为 S2 后的更新状态）

假设	S1+S2 数据	判定更新
H1 饱和：B≥60 时 DE 的 NLL 随 k 改善但边际递减；B120 时 k5 与 k8 差距在等效界内	B120 等效维持（−0.0056）；B240 处 k5–k8 差距 −0.0355 拒绝等效，k 曲线未饱和；k*(B) 序列 3→[3,5]→[5,8]→≥8	支持且强化（新增“外推端更强”），补充边界声明：网格上限 k=8 未覆盖 B240 真实最优
H2 放大：DE−SG 差距随 B 单调扩大且主要由 Single 恶化贡献	四点 −0.0754/−0.2245/−0.3317/−0.2465 全 p=0.0020、CI 分离；但非单调（B120 峰值）；Single 份额 98.6%/131%/12.6%	修正为条件命题（D6）：双条件（Single 恶化 × 甜区内分配）下放大；B240 处两条件分别失效
H3 快照差距：DE−SN 差距随 k 增大收窄	S1 已推翻（B30k5 反转 +0.0096）；B240 呈非单调（k3 最深 −0.1426，k8 回升 −0.1177）；全部 14 设置快照无一最优	维持推翻；新增大预算下快照成员质量劣势的机制证据

假设	S1+S2 数据	判定更新
H5 温度缩放：TS 压缩但不消除 B≥60 的 k 效应与 DE−SG 差距；B30 处趋于拉平	TS 后 DE−SG(k3)：−0.0114/−0.0434/−0.0567/−0.0503（全 p=0.0020，四点保留）；“B30 拉平”S1 已修正；TS 最优 k 下移规则 B240 失效（D7）	部分支持（压缩但不消除成立）；下移规则条件化（甜区内成立）
H4 边界（MNIST 衰减/CIFAR 放大）	S3 范围，未涉及	待 S3
H6 推理成本	A2 范围，未涉及	待 A2

八、偏离登记（S2 新增）

编号	偏离	处置
D6	H2“单调扩大”表述与 B240 数据不符（差距收窄 0.0852）；G2 字面判据（CI 不重叠/反向）未触发，但单调性主张失效	修正为条件命题（双条件放大），机制分解支持；论文表述按新形状撰写；S3 启动授权不受影响
D7	S1 发现的“TS 后最优 k 下移一档”在 B240 失效（k8 仍最优，差 0.010 恰在等效界）	条件化为“甜区内成立”；作为 e 甜区机制的第三独立证据写入论文
D8	执行层三次事件：两次会话中断 + 一次 600 秒硬超时静默失败（子进程被杀、该种子未写入）	零数据损失（逐种子追加写入 + 截断行忽略 + I1 兜底校验）；重试成功；登记以保持执行透明
D9	S2 实测 3.06 h vs 预算 3–4 h	预算内完成，无处置需要
D10	驱动脚本打包参数在执行中期调整（静态 guard → 动态 guard，TB 上限 330→585 秒）	仅影响分片打包效率（1–2 种子/片），不触碰实验代码、种子与指标路径；k|B 约束与断点协议不变；I1–I6 验证打包调整未引入任何数据差异

九、S3 启动判定与后续计划

S3 获得启动授权。G2 字面判据通过（表 3-1），全局停止规则三条件均未命中：(a) 无设计缺陷——B240 的 I3 结构性验证（Single 跨 k 位级一致）确认预算记账公平 (b) 无波动崩溃——四单元种子间标准差 0.0012–0.0097（NLL），与 S1 同量级；(c) 核心机制未消失——甜区机制在 B240 的三个独立证据方向（k 曲线、放大分解、TS 边界）全部一致。预注册网格的剩余阶段如下。

表 9-1 剩余阶段与判定目标

阶段	内容	算力估计	判定目标	状态
S3 迁移	MNIST B120×{k2,5} + CIFAR-10 B60×{k2,5}	≈1 h + ≈2 h	H4 边界：MNIST 衰减（近饱和域）与 CIFAR 放大（高难度域）；甜区机制的跨域稳健性	已授权，待执行

阶段	内容	算力估计	判定目标	状态
A1 消融	Single 验证集早停版 B30/60/120	≈0.5 h	RQ5：选择规则（早停 vs 固定长度）是否改变分配建议	无前置门，可与 S3 并行
A2 基准	推理延迟/参数/存储 k 扫描	<10 min	H6：部署成本的独立报告	无前置门
论文重写	v5 全文（重定位：分配相图）	—	三个机制曲线 + 条件化规律 + 14 设置全网格	S3+A1+A2 后启动

S3 的两个域的预测（预注册推断，供事后对照）：MNIST 为近饱和域（v4 已知单轨迹策略在 B120 处不显著），预期 k 曲线更平坦、甜区更宽（更短训练即可饱和），k* 上移规律可能减弱；CIFAR-10 为高难度域（CNN 架构），预期放大更强、甜区更窄。若两个预测方向均复现，H4 的边界条件表述将获得与 FMNIST 同等强度的支持；若任一方向不符，按预注册判据如实修正边界表述。

十、可核验性

- 原始记录：ijmlc-repo/results/v5/experiment_v5_fmnist_B240_k{2,3,5,8}.jsonl（4 文件，40 条逐种子记录，含版本戳、wallclock、逐条件全指标、TS 拟合值、可靠性分箱与成员级指标）
- 分析输出：results/v5/analysis_v5.json（S1+S2 合并 14 单元全统计，含 G2 判定块；S1-only 版备份为 analysis_v5_S1only_backup.json）、summary_v5.csv（扩展至 98 行）、contrasts_v5.csv（族一 70 行 + 族二 18 行）
- 脚本：scripts/run_s2_driver.py（分片驱动，动态 guard 打包）、scripts/check_s2_integrity.py（S2 六项核验）、scripts/analyze_v5.py（扩展至 14 单元，输出 G2 判定）
- 复现命令：python scripts/run_s2_driver.py 595（断点续跑至 ALL_S2_CELLS_DONE）；python scripts/check_s2_integrity.py；python scripts/analyze_v5.py
- 本报告全部数值与 analysis_v5.json 逐项对应；执行层事件（D8）的完整时间线见分片日志与本报告第二节