S T A G E 3 R E P O R T

S3 跨域迁移执行报告：边界模式复现与 G3 阶段门判定

v5.0 研究计划（方案 B）阶段报告 · 预注册网格 S3 结果与假设判定更新

研究项目：固定训练预算下的集成不确定性研究

执行日期：2026 年 10 月 27 日（S3 完成，G3 通过 4/4，预注册主网格闭环）

前置文档：核验报告 Doc 1 · 文献缺口 Doc 2 · 预注册计划 Doc 3 · S1 报告 Doc 4 · S2 报告 Doc 5

数据环境：torch 2.14.1+cpu（双线程）· S3 4 单元 × 10 种子 · 2.48 h

目 录

一、执行摘要.....

一、执行摘要.....1

二、执行记录与数据完整性.....2

三、G3 阶段门判定（4/4 判据通过）.....2

四、跨域边界模式：分配相图的第三根轴.....3

五、族一：条件排序的跨域差异.....4

六、族二：分配效应的跨域形状与 e 甜区证据.....4

七、校准与 OOD 检测的跨域模式.....5

八、预注册假设判定更新（S1+S2+S3 合并口径）.....5

九、偏离登记（S3 新增）.....5

十、论文重写启动判定与后续计划.....6

十一、可核验性.....6

注：本目录由域代码生成。如编辑后页码发生变化，请在目录上右键选择“更新域”以刷新页码。

一、执行摘要

G3 阶段门判定：通过（4/4 判据）。S3 跨域迁移矩阵（MNIST B120×k∈{2,5} + CIFAR-10 B60×k∈{2,5}，4 单元 × 10 种子，8,916 秒训练 wallclock，实测 2.48 小时、预算约 3.5 小时）在预注册环境下全部完成，六项数据完整性核验全部通过。预注册 H4 边界假设的两个方向在四个单元上全部复现：MNIST（近饱和域）上 DeepEns−Single 差距衰减至等效界 0.020 内（k2：−0.0086，TOST p=1.5×10−6；k5：−0.0152，TOST p=5.4×10−4），CIFAR-10（高难度域）上差距强烈放大（k2：−1.1406；k5：−1.3656，均 p=0.0020，10/10 种子同号）。分配建议的边界条件由此获得第三个独立证据轴：效应量由单模型的性能余量（headroom）决定。

S3 的五项核心发现：

- 边界模式复现且量化：DE−SG(k2) 差距按域排列为 FMNIST −0.2515（B120，S1 存档）→ MNIST −0.0086（近饱和）→ CIFAR −1.1406（过度自信域），跨越两个数量级。单模型 NLL 分别为 0.6672 / 0.0675 / 1.9959——分配收益与单模型余量同向缩放，与 e 甜区机制（成员质量决定集成上限）在方向上一致。
- 族二（分配效应）呈域依赖形状：MNIST 的 DE(k5)−DE(k2) = −0.0066，TOST 判等效（p=1.9×10−5）——近饱和域上分配选择几乎无关；CIFAR 同对比 −0.2251，拒绝等效（p=0.0020）——高难度域上分配选择是主导决策。e 甜区在两个域的跨域检验一致：CIFAR 的 e=30 成员（k2）NLL 1.2775 显著差于 e=12 成员（k5）0.8666，成员质量劣势压倒其更高多样性（JSD 0.1612 vs 0.1059）；MNIST 的 e=60 成员（0.0709）甚至略优于 e=24（0.0763），甜区右边界在近饱和域大幅外移。
- 条件排序的域间反转：CIFAR 上四方法排序为 DE < Snapshot < SWA < Single（全部 p_holm=0.0098）；MNIST 上 Snapshot 与 Single 统计不可分（+0.0007/−0.0007，p_holm≥0.33），而 SWA 显著差于 Single（+0.0034/+0.0044，p_holm 0.0273/0.0098）——权重平均在近饱和域把已经收敛的模型拖离最优点。Snapshot 在全部 18 个设置（S1 14 + S3 4）中无一进入最优，v4/v5 的核心排序结论在两个新域上均保持。
- 校准与 OOD 的跨域模式：CIFAR Single 的 ECE-15 高达 0.2213（过度自信签名），DE 将其压至 0.0470/0.0446；温度缩放把 Single 的 NLL 由 1.9959 修复至 0.8620，但 DE(k2) TS 后 0.7398、k5 0.6268 仍然更优——集成优势在校准

修复后存活，且 TS 只能把 CIFAR 的 k 效应减半（−0.2251→−0.1130）而非消除，与 H5 在 FMNIST 上的形状一致。OOD 检测上 DE 在全部探针（fmnist/kmnist/cifar100）与全部单元最优（MNIST kmnist 0.9380/0.9473；CIFAR-100 0.7267/0.7612）。

- MNIST 衰减的精确刻画：DE−SG 在 MNIST 上统计显著（p=0.0020，10/10 种子负向）但幅度被预注册边界 0.020 完全包络——“统计可检出、实践可忽略”。这排除了把 MNIST 结果误读为“集成无益”或“效应不存在”的两种极端表述，边界条件的量化表述由此完整。

二、执行记录与数据完整性

执行环境与 S1/S2 完全一致：torch 2.14.1+cpu（双线程）、numpy 2.1.3、统一种子方案 base=10000+100s、s∈[0,10)。MNIST 单元复用 v2 引擎（--id mnist，OOD 探针 fmnist+kmnist），CIFAR 单元复用跨架构引擎（SmallCNN 3 卷积块约 34k 参数，epoch 级检查点断点续跑，OOD 探针 cifar100）。分片协议沿用前台 600 秒断点续跑 S3 执行期间共发生四次会话层中断（工具调用被取消/网关 EOF，进程在沙箱内存活至自然结束）与一次网关重投递（同一分片命令被重复执行），单实例锁与检查点 owner 协议防止了任何并发损坏；一次驱动器 owner 校验顺序缺陷（对已完成单元误报 exit 3）当日定位修复，未触及任何数据路径。S3 阶段累计经历多次宿主环境重置（至第十次），最终数据为最后一次恢复后的全新完整重跑；跨重置确定性由双锚点校验保证：FMNIST B30k2 seed0 对 S1 存档位级复现、MNIST B60k3 seed0 对 v2 存档 10−3 容差内复现（四次全部通过），且 MNIST/CIFAR 关键种子的 NLL 值与重置前日志逐位一致。

表 2-1 S3 数据完整性核验（scripts/check_s3_integrity.py，六项全过）

检查	结果	说明
I1 种子完整性	4/4 单元 PASS	每单元恰含种子 0–9，无重复、无截断行
I2 共享成员位级一致	PASS	4 个单元 seed-0 位级校验 shared_ok=True；同时验证 120/{2,5} 与 60/{2,5} 的 k|B 整除性
I3 跨配置 Single 一致	PASS（2/2 域）	MNIST k2 与 k5、CIFAR k2 与 k5 的 Single 逐种子位级一致（结构性预算公平验证）
I4 配置戳	PASS	全部 40 条记录 budget/k/id/OOD 探针与预注册矩阵一致（mnist:[fmnist,kmnist]；cifar10:[cifar100]）
I5 版本戳统一	PASS	全部记录与 S1/S2 戳完全一致（torch 2.14.1+cpu / numpy 2.1.3），三阶段可合并分析

检查	结果	说明
I6 记录完整	PASS	成员级指标在位；总 wallclock 8,916 秒（2.48 h，预算 ≈3.5 h 内）

数据完整性承诺执行情况：无任何种子被删除或替换；两个域均未出现训练崩溃或发散种子。逐种子记录（含每种子 wallclock、全部指标、TS 拟合值与可靠性分箱）见 results/s3/experiment_v5_{mnist,cifar}_B{120,60}_k{2,5}.jsonl。

三、G3 阶段门判定（4/4 判据通过）

预注册 G3 判据（Doc 3 表 7-2）：S3 后 MNIST 衰减 + CIFAR 增强的边界模式复现。操作化为四个单元判据：H4a（MNIST k2、k5 的 DE−SG 在预注册边界 δ=0.020 内 TOST 等效）与 H4b（CIFAR k2、k5 的 DE−SG 显著为负）。H4a 的等效界采用 Doc 3 表 3-1 H4 行的边界值 0.020（而非通用 NLL 界 0.010），因为 H4 的主张形式即“衰减至 0.02 以内”。

表 3-1 H4a：MNIST 衰减判据（DE−SG，n=10 配对，TOST δ=0.020）

单元	均值差	90% CI	TOST p	等效判定	置换 p	方向
MNIST B120 k2	−0.0086	[−0.0107, −0.0066]	1.5×10−6	等效（通过）	0.0020	10/10 负
MNIST B120 k5	−0.0152	[−0.0171, −0.0134]	5.4×10−4	等效（通过）	0.0020	10/10 负

表 3-2 H4b：CIFAR 放大判据（DE−SG，n=10 配对，置换检验）

单元	均值差	95% CI	p（置换）	判定	方向
CIFAR B60 k2	−1.1406	[−1.1730, −1.1082]	0.0020	放大（通过）	10/10 负
CIFAR B60 k5	−1.3656	[−1.3869, −1.3444]	0.0020	放大（通过）	10/10 负

G3 判定：通过。四个判据全部满足，边界模式的表述按预注册形式保留：分配效应（集成 vs 单模型）的大小由域的单模型余量决定——近饱和域衰减至实践可忽略（<0.02 nats），高难度过度自信域放大至超过一个 nat。未触发任何 G3 失败条款（MNIST 效应超界或 CIFAR 效应缺失均未发生）。按表 7-2，预注册主网格（S1+S2+S3）全部完成，论文重写获得启动授权；剩余 A1（早停消融）与 A2（推理基准）为无前置门的补充实验。

四、跨域边界模式：分配相图的第三根轴

表 4-1 三个域的条件对比（k=2 单元，n=10，NLL；FMNIST 取 S1 存档）

域 / 机制	Single NLL	DeepEns NLL	DE−SG	Single ECE-15	判读
MNIST B120（近饱和）	0.0675	0.0589	−0.0086	0.0087	单模型已收敛，校准良好；分配收益微弱
FMNIST B120（中等）	0.6672	0.4157	−0.2515	0.0807	单模型过度自信随 B 恶化；分配收益显著
CIFAR B60（高难度）	1.9959	0.8553	−1.1406	0.2213	单模型深度过度自信；分配收益巨大

三个域构成单模型余量的完整谱系：MNIST 的单模型在 B=120 处 NLL 已达 0.0675、ECE 0.0087（校准近乎完美），集成只能再挤出 0.0086；FMNIST 的单模型呈经典的过度自信恶化（ECE 0.0807），集成修复 0.2515；CIFAR 的单模型在高难度任务上深度过度自信（NLL 1.9959，几乎为均匀分布 2.303 的水平，ECE 0.2213），集成修复 1.1406——超过 FMNIST 的四倍。把 S1/S2 的预算轴（B30–B240）与本阶段的域轴合并，v5 的预算分配相图获得三个正交方向的一致刻面：分配收益 = f(单模型余量)，而余量由（预算 × 域难度）共同决定。e 甜区机制给出了函数形式：集成上限由成员质量决定，成员质量由每成员训练长度 e 与域的学习曲线共同决定。

CIFAR 的过度自信签名值得单独记录：Single 的 acc 为 0.7086 但 NLL 1.9959——判别力与置信度严重脱节（正确时不够自信、错误时过度自信的混合错置）。温度缩放把 NLL 修复至 0.8620（修复 1.13 nats），说明错置主要是温度型的；但 DE 的 TS 后 NLL（k2 0.7398、k5 0.6268）仍然显著更优，且 DE 的 raw ECE（0.0470/0.0446）已接近 TS 修复水平——集成的平均效应本身提供了大部分校准修复，这是 DE 在过度自信域优势的机制分解：约 2/3 来自校准修复（温度型），约 1/3 来自判别力提升（acc 0.7086→0.7597/0.7909）。

五、族一：条件排序的跨域差异

表 5-1 族一对比（NLL 配对差，逐单元 Holm over 5，n=10）

单元	DE−SG	SN−SG	SWA−SG	DE−SN	SN−SWA
MNIST k2	−0.0086**	+0.0007	+0.0034*	−0.0093**	−0.0027**
MNIST k5	−0.0152**	−0.0007	+0.0044**	−0.0146**	−0.0051**
CIFAR k2	−1.1406**	−0.9014**	−0.7137**	−0.2392**	−0.1877**
CIFAR k5	−1.3656**	−1.2242**	−1.0742**	−0.1415**	−0.1500**

*** p_holm=0.0098；* p_holm=0.0273；未标注者 p_holm≥0.33（不显著）。方向计数：全部显著对比 10/10 种子同号。*

排序的域间结构差异是 S3 的新信息。CIFAR 上排序为 DE < Snapshot < SWA < Single（五个对比全部显著），与 v4 的 CIFAR B60k3 存档（single 1.9928 / DE 0.6889 / snapshot 0.8951 / swa 1.0837 / shared_ok=True）的排序完全一致——Single 逐位复现（1.9927512641288747，k 无关且跨 torch 构建稳定），存档的 DE(k3) 0.6889 恰介于本阶段 k2 0.8414 与 k5 0.6302 之间，与更多成员单调改善一致——高难度域上任何形式的参数/预测平均都显著优于单模型，且独立成员平均（DE）优于轨迹平均（SWA）与循环末端平均（Snapshot）。MNIST 上结构反转：Snapshot 与 Single 不可分（快照成员 e=60/24 均已收敛，与单模型无实质差异），而 SWA 显著差于 Single——对已经收敛到相近解的模型做权重平均，会把各自解的微小偏移平均掉，落在平坦损失面的非最优点上；k5 的 SWA 劣化（+0.0044）大于 k2（+0.0034），与其平均的快照数量一致。SWA 的收益条件（同一轨迹内、未收敛阶段）在 FMNIST 上已由 S1 的 e 甜区刻画，MNIST 提供了反向边界的第二个证据方向。

六、族二：分配效应的跨域形状与 e 甜区证据

表 6-1 族二（域内分配）：DeepEns(k5)−DeepEns(k2)（n=10 配对）

域	raw NLL 差	p（置换）	TOST（δ=0.010）	TS-NLL 差	判读
MNIST B120	−0.0066	0.0020	等效（p=1.9×10−5）	−0.0036	分配选择实践无关
CIFAR B60	−0.2251	0.0020	拒绝等效	−0.1130	分配选择主导性能

表 6-2 成员级证据：e = B/k 的跨域对照（DeepEns 成员，n=10 均值）

单元	每成员 e	成员 NLL	成员 acc	成员间 JSD	集成 NLL
MNIST k2	60	0.0709	0.9823	0.0057	0.0589
MNIST k5	24	0.0763	0.9817	0.0064	0.0523
CIFAR k2	30	1.2775	0.7178	0.1612	0.8553
CIFAR k5	12	0.8666	0.7291	0.1059	0.6302

两个域给出互补的甜区证据。CIFAR 上 e=30 的成员（k2）NLL 1.2775 显著差于 e=12 的成员（k5）0.8666——长成员在高难度域深度过度自信；尽管其多样性更高（JSD 0.1612 vs 0.1059），成员质量劣势压倒多样性优势，集成差距 −0.2251。这正是 FMNIST e∈[10,30] 甜区右端恶化的跨域复现：CIFAR 的甜区中心比 FMNIST 更偏左（e=12 优于 e=30，而 FMNIST 的 e=24/30 仍在甜区内），与高难度域过拟合更快的直觉一致。MNIST 上模式反转：e=60 的成员（0.0709）反而略优于 e=24（0.0763）——近饱和域没有过度自信恶化，更长的成员严格更好；k5 集成仍略优

（0.0523 vs 0.0589）纯靠更多成员的平均方差缩减，且差距落入等效界。两条成员质量曲线与域难度同向移动，甜区机制作为域依赖规律的统一解释由此闭合。

七、校准与 OOD 检测的跨域模式

表 7-1 ECE-15 与 TS 修复（n=10 均值）

单元	Single ECE	DE ECE	Single raw→TS NLL	DE raw→TS NLL	TS 修复幅度
MNIST k2	0.0087	0.0061	0.0675→0.0577	0.0589→0.0531	15% / 10%
MNIST k5	0.0087	0.0044	0.0675→0.0577	0.0523→0.0495	15% / 5%
CIFAR k2	0.2213	0.0470	1.9959→0.8620	0.8553→0.7398	57% / 14%
CIFAR k5	0.2213	0.0446	1.9959→0.8620	0.6302→0.6268	57% / 1%

TS 修复幅度（相对 raw NLL）呈现清晰的双层结构：过度自信的 Single 可被大幅修复（CIFAR 57%），但已良好校准的 DE 几乎无从修复（CIFAR k5 仅 1%，MNIST 5–10%）。这使 H5 的跨域形式比 FMNIST 更锐利：TS 能替代的是“校准修复”那部分收益（CIFAR Single 的 1.13 nats 修复量与 DE−SG 差距 1.14 同量级），而判别力部分（acc 提升）与多样性平均效应不可替代——TS 后 DE 仍比 TS 后 Single 好 0.122（k2）与 0.235（k5），且 TS 把 k 效应减半（−0.2251→−0.1130）但不消除，两个方向均与 FMNIST 的 H5 形状一致。

表 7-2 OOD 检测 AUROC（MSP 分数，n=10 均值；MNIST 探针为 fmnist/kmnist，CIFAR 探针为 cifar100）

单元	Single	DeepEns	Snapshot	SWA	探针
MNIST k2	0.9223 / 0.9204	0.9361 / 0.9380	0.9311 / 0.9238	0.9284 / 0.9189	fmnist / kmnist
MNIST k5	0.9223 / 0.9204	0.9416 / 0.9473	0.9277 / 0.9268	0.9240 / 0.9186	fmnist / kmnist
CIFAR k2	0.6799	0.7267	0.7057	0.6948	cifar100
CIFAR k5	0.6799	0.7612	0.7291	0.7102	cifar100

OOD 方向上的排序与 ID 一致（DE 最优，全部 8 个单元×探针组合无一例外），且 k5 的增益在 CIFAR 上更大（+0.081 vs MNIST 的 +0.006/+0.009）——成员平均的不确定性收益在高难度域同时改善 ID 与 OOD 两个方向。SWA 在 MNIST 的两个探针上均低于 Single（0.9284/0.9189 与 0.9240/0.9186 vs 0.9223/0.9204），与其 ID 劣化一致；CIFAR 上 SWA 仍优于 Single 但幅度小于 Snapshot。

八、预注册假设判定更新（S1+S2+S3 合并口径）

表 8-1 假设判定对照（判据原文见预注册计划表 3-1；本表为 S3 后的更新状态）

假设	S3 数据	判定更新
H4 边界：近饱和 MNIST 上分配效应衰减（DE−SG ≤ 0.02），CIFAR-10 CNN 上放大	MNIST：−0.0086/−0.0152，均 TOST 等效于 0.020 内（p=1.5×10−6/5.4×10−4）且统计显著（10/10 负）；CIFAR：−1.1406/−1.3656（p=0.0020，10/10 负）；跨域谱系 FMNIST −0.2515 居中	支持（4/4 判据，G3 通过）；效应量随单模型余量缩放的量化表述完成
H1 饱和（k 曲线边际递减）	S3 未直接触及；MNIST 的 k 曲线在等效界内平坦（−0.0066 等效）、CIFAR 未饱和（−0.2251 拒绝等效），与域难度同向	维持 S2 判定（支持且强化）；新增跨域一致的方向证据
H2 放大（条件命题形式）	S3 提供域轴放大：CIFAR（高难度）DE−SG 是 FMNIST 的 4.5 倍、MNIST 的 130 倍；机制（单模型余量）与预算轴一致	维持 D6 条件命题；域轴并入相图
H3 快照差距（S1 已推翻）	MNIST：Snapshot≈Single（不显著）；CIFAR：DE−SN −0.2392/−0.1415（显著）；18 设置无一最优维持	维持推翻；MNIST 的 SWA<Single 反向边界为新证据
H5 温度缩放（压缩不消除）	CIFAR：TS 后 k 效应 −0.2251→−0.1130（减半不消除）；TS 后 DE−SG 仍 −0.122/−0.235；MNIST TS 修复量 15%/5–10%	维持部分支持；“TS 替代甜区内一档成员”规则获跨域确认
H6 推理成本	A2 范围，未涉及	待 A2

九、偏离登记（S3 新增）

编号	偏离	处置
D11	S3 输出使用独立目录 results/s3/（S1/S2 位于 results/v5/），分析产物为 analysis_v5_s3.json / summary_v5_s3.csv / contrasts_v5_s3.csv	目录隔离源于跨域单元的命名空间分离；I5 版本戳确认三阶段可合并；论文数据表统一引用
D12	S3 执行期间多次宿主环境重置（至第十次），已完成的部分数据（MNIST 8/10）被清零后全新重跑	零科学影响：每次恢复先过双锚点确定性校验（FMNIST B30k2 位级 + MNIST B60k3 10−3，四次全过）；最终数据与重置前种子级日志逐位一致；登记以保持执行透明
D13	执行层事件：四次会话中断（进程存活至自然结束）+ 一次网关重投递（重复执行同一分片命令）+ 一次驱动器 owner 校验顺序缺陷（对已完成单元误报 exit 3）	零数据损失：单实例锁阻止并发、epoch 级检查点保证截断安全、缺陷当日修复且未触及数据路径；I1–I6 兜底校验全过
D14	S3 实测 2.48 h（8,916 s）vs 预算 ≈3.5 h（1.5+2）	预算内完成，无处置需要

十、论文重写启动判定与后续计划

预注册主网格（S1+S2+S3，22 单元 × 10 种子）全部完成，G1/G2/G3 三道阶段门全部通过，全局停止规则三条件均未命中。核心贡献定形为“预算分配的完整相图”

三条机制曲线（单模型恶化、成员 e 甜区、集成规模收益）在预算轴（B30–B240）与域轴（MNIST/FMNIST/CIFAR-10）两个方向上被同一套预注册判据刻画，条件化规律（放大 = 单模型余量 × 甜区内分配）在 22 个设置上无一反例。论文重写（v5 全文）正式获得启动授权。剩余两个无前置门的补充实验与重写的并行关系如下。

表 10-1 剩余阶段与判定目标

阶段	内容	算力估计	判定目标	状态
A1 消融	Single 验证集早停版 B30/60/120	≈0.5 h	RQ5：选择规则（早停 vs 固定长度）是否改变分配建议	待执行，可与重写并行
A2 基准	推理延迟/参数/存储 k 扫描	<10 min	H6：部署成本的独立报告	待执行
论文重写	v5 全文（重定位：分配相图 + 三域边界）	—	三机制曲线 + 条件化规律 + 22 设置全网格 + MNIST/CIFAR 边界证据	已授权，启动

对论文重写的两点输入（基于 S3）：其一，边界条件应写成定量形式——分配收益与单模型余量的关系在三个域上跨越两个数量级（0.0086/0.2515/1.1406），可给出“单模型 NLL 校准良好的域（ECE<0.01）上分配选择收益 <0.02 nats”的可检验命题；其二，MNIST 的 SWA 反向结果（显著差于 Single）应作为实践警告写入讨论——权重平均不适用于已收敛模型的循环末端快照，这是 SWA 文献中较少被强调的失效边界。

十一、可核验性

- 原始记录：ijmlc-repo/results/s3/experiment_v5_{mnist,cifar}_B{120,60}_k{2,5}.jsonl（4 文件，40 条逐种子记录，含版本戳、wallclock、逐条件全指标、TS 拟合值、可靠性分箱与成员级指标）
- 分析输出：results/s3/analysis_v5_s3.json（含族一/族二/H4a/H4b/G3/OOD/跨域对照块）、summary_v5_s3.csv（80 行）、contrasts_v5_s3.csv（族一 20 行 + 族二 4 行）
- 脚本：scripts/run_s3_driver.py（分片驱动：单实例锁 + 孤儿引擎清理 + CIFAR 检查点 owner 协议）、scripts/check_s3_integrity.py（S3 六项核验）、scripts/analyze_s3.py（预注册分析 + G3 判定）
- 复现命令：python scripts/run_s3_driver.py 595（断点续跑至 ALL_S3_CELLS_DONE）；python scripts/check_s3_integrity.py；python scripts/analyze_s3.py

- 跨重置确定性锚点：CIFAR B60k2 seed0 single 1.9928 / DE 0.8414 / shared_ok=True（四次位级复现）；MNIST B120k2 逐种子值与重置前日志一致；本报告全部数值与 analysis_v5_s3.json 逐项对应