A B L A T I O N & B E N C H M A R K R E P O R T

A1/A2 消融与基准执行报告：选择规则的机制分解与推理成本刻画

v5.0 研究计划（方案 B）阶段报告 · 预注册网格收尾（RQ5 早停消融 + H6 推理基准）

研究项目：固定训练预算下的集成不确定性研究

执行日期：2026 年 10 月 27 日（A1/A2 完成，预注册实验网格 S1+S2+S3+A1+A2 全部闭环）

前置文档：核验报告 Doc 1 · 文献缺口 Doc 2 · 预注册计划 Doc 3 · S1 报告 Doc 4 · S2 报告 Doc 5 · S3 报告 Doc 6

数据环境：torch 2.14.1+cpu（双线程）· A1 3 单元 × 10 种子 0.27 h · A2 31 s

目 录

一、执行摘要.....
二、执行记录与数据完整性.....
三、RQ5 判定：选择规则改变基础事实.....
四、分配建议的重新解读.....
五、选择行为与校准.....
六、A2：推理成本基准（H6）.....
七、机制综合：选择规则作为分配相图的隐藏维度.....
八、预注册假设判定更新（A1/A2 收尾）.....
九、偏离登记（A1/A2 新增）.....
十、论文重写：数据就绪与输入清单.....
十一、可核验性.....

注：本目录由域代码生成。如编辑后页码发生变化，请在目录上右键选择“更新域”以刷新页码。

一、执行摘要

A1 选择规则消融与 A2 推理基准全部完成。A1（FMNIST B30/60/120 早停版 Single，3 单元 × 10 种子，训练 wallclock 978 秒 ≈ 0.27 小时，预算约 0.5 小时）以 360 个位级锚点（30 种子 × 12 指标）验证与主网格完全位级一致后，给出了 RQ5 的明确答案：

早停使"单模型预算越大越差"的基础事实基本消失。最终权重规则下 Single 的测试 NLL 从 B30 到 B120 恶化 +0.2877（p=0.0020，10/10 种子同向）；验证集早停规则下同一恶化缩小 40 倍至 +0.0072（30→120 名义 p=0.0352，但量级 0.007 低于预注册等效界 δ=0.010；分段 30→60 与 60→120 均不显著）。单模型随预算的恶化不是预算的内在属性，而是"取最终权重"这一选择规则与训练后期过度自信的交互产物。

分配建议的方向不变、幅度大减，且出现一个符号反转。早停规则下 DE(k2)−Single 的收益从 −0.0730/−0.1948/−0.2515（final 规则，B30/60/120）缩水至 −0.0369/−0.0173/+0.0651：B120 处早停 Single（0.3506）反超 DE(k2)（0.4157）——两个 60-epoch 成员各自停在过训区，输给一个停在验证最优的 120-epoch 模型。但最优分配仍在集成侧：B120 处 DE(k8)（0.2909）仍比早停 Single 好 0.0597。机制解读：DeepEns 随 k 的收益中相当一部分来自"成员隐式早停"（短成员 e=B/k 提前脱离过训区），独立重启的净多样性贡献在早停基线校正后约为 0.05 nats。

温度缩放吸收两规则差距的 96%。B120 处 final 与 ES 的 raw 差距 0.3166，TS 后仅剩 0.0117（final TS 0.3485 vs ES TS 0.3368）；B30/B60 处 TS 后两规则差距分别为 −0.0123/+0.0026（final 略优）。后期恶化的主体是温度型过度自信，早停与温度缩放是两个近似可互换的修复手段——这为 H5 的机制版式提供了选择规则维度的第三重确认。

A2（H6，31 秒完成）：推理成本随成员数 k 线性增长。概率平均的延迟线性拟合 R^2 = 0.988–0.9998（MLP：batch=1 每成员 0.069 ms、batch=256 每成员 0.556 ms；CNN：batch=1 每成员 0.411 ms、batch=256 每成员 48.0 ms）；权重存储严格 k×（MLP 0.438 MB/成员，CNN 0.135 MB/成员），常驻内存 RSS 差分 3.5 MB 与 8×0.438 精确吻合。H6 的描述性判据全部满足。

二、执行记录与数据完整性

执行环境与 S1/S2/S3 完全一致（torch 2.14.1+cpu 双线程、numpy 2.1.3、统一种子方案 base=10000+100s）。A1 由专用引擎 code/run_ablation_earlystop.py 执行：训练循环为 common.train_run 的逐行复制（cycles=1 无快照路径）加最优权重跟踪，独立成文件以避免改动被 v1/v2/SWA/S3 引擎共享的 common.py；复制的正确性不靠审查保证而靠数据保证——每种子 final-epoch 指标与 S1 主网格同一 (B, seed) 的 single 记录位级一致（共 30 种子 × 12 指标）。选择规则在运行前写定：逐 epoch 验证 NLL（主引擎本就执行的监控前向，Doc 3 表 5-1 不计入预算）取严格更小者为新最优，平局保留最早 epoch。A1 分片执行 4 次调用全部自然完成（B30/B60 各一次，B120 一次），无重试、无孤儿进程；A2 由 scripts/benchmark_inference.py 一次完成（TORCH_THREADS=2 与网格一致，k∈{1,2,3,5,8}，warmup 10 次后重复 30–400 次 median 与 mean±sd 双报以容纳 CPU 计时抖动）。

表 2-1 A1 数据完整性核验（scripts/check_a1_integrity.py，七项全过）

检查	结果	说明
I1 种子完整性	3/3 单元 PASS	每单元恰含种子 0–9，无重复、无截断行
I2 版本戳统一	PASS	全部记录与 S1/S2/S3 戳完全一致（torch 2.14.1+cpu / numpy 2.1.3）
I3 配置戳	PASS	id=fmnist、budget 正确、消融标记与选择规则（含平局规则）在每条记录在位
I4 final 与 S1 位级一致（raw）	PASS	30 种子 × {nll, acc, brier, ECE15, ECE10} 全部逐位相等，0 失配
I5 final 与 S1 位级一致（TS）	PASS	30 种子 × {TS-NLL, acc, brier, ECE15, ECE10, T, val-NLL} 全部逐位相等，0 失配
I6 选择一致性	PASS	best_epoch ∈ [1,B]、history 长度 = B、best_val_nll = 验证曲线最小值、平局规则核验通过
I7 ES 指标	PASS	全部 ES 指标有限且在位（raw + TS + OOD 探针）

预算记账（Doc 3 表 5-1）：A1 计入训练预算的优化器更新为每种子每单元 B epochs（合计 2,100 epochs）；逐 epoch 验证监控前向与主网格等量等价，不计入。A1 训练 wallclock 978 秒（0.27 h，预算 0.5 h 内）；A2 为纯推理基准，不入训练预算。冒烟记录 smoke/smoke_a1_fmnist_B30_seed0.jsonl 仅为引擎验证（其 final 指标与 S1 位级一致后即弃用），不进入任何分析。

三、RQ5 判定：选择规则改变基础事实

RQ5（Doc 3 第一节）：模型选择规则（最终权重 vs 验证集早停）是否改变“单模型预算越大越差”的基础事实，从而改变分配建议？消融设计把该问题拆为三步：规则内对比（T1，早停带来多大修复）、跨预算对比（T2/T3，早停后恶化是否存

活）、分配收益对比（T4，见下节）。全部对比为种子内配对，精确符号翻转置换检验（n=10 时未校正下限 p=0.0020），95% t-CI；A1 为消融性分析，无预注册假设或等效界适用，下表量级解读中借用的 δ=0.010 仅为预注册分辨率的参照刻度。

表 3-1 T1：ES 与 final 的逐预算配对对比（测试 NLL，n=10）

预算	ES NLL	final NLL	配对差 ES−final	95% CI	p（置换）
B30	0.3434 ± 0.0092	0.3795 ± 0.0085	−0.0361	[−0.0426, −0.0296]	0.0020
B60	0.3491 ± 0.0071	0.5265 ± 0.0139	−0.1774	[−0.1881, −0.1667]	0.0020
B120	0.3506 ± 0.0062	0.6672 ± 0.0213	−0.3166	[−0.3298, −0.3035]	0.0020

表 3-2 T2/T3：跨预算恶化的两规则对照（配对差，n=10）

预算跨度	ES 规则恶化	95% CI	p	final 规则恶化	95% CI	p
30 → 60	+0.0057	[−0.0004, +0.0118]	0.0723	+0.1470	[+0.1367, +0.1573]	0.0020
60 → 120	+0.0015	[−0.0020, +0.0050]	0.3516	+0.1407	[+0.1235, +0.1579]	0.0020
30 → 120	+0.0072	[+0.0008, +0.0136]	0.0352	+0.2877	[+0.2776, +0.2978]	0.0020

判定：早停消除基础事实。final 规则的恶化（T3 列）与 S1 主网格的 Single 恶化完全一致（互为校验）；同一批种子在早停规则下（T2 列）三个预算跨度的恶化全部低于 0.008，其中两段不显著，唯一名义显著的 30→120（p=0.0352）幅度 0.0072 也落在预注册等效界 0.010 之内。恶化幅度被压缩 40 倍（0.2877 → 0.0072），且随预算增大的剩余斜率不呈加速。结论按 RQ5 的问法正面回答：基础事实（单模型随预算恶化）在早停规则下不再成立，它是选择规则与后期过度自信的交互产物；这一结论与 H2 的机制分解（放大差距主要由 Single 恶化贡献）在更深的层次上汇合——恶化本身是温度型的、可被早停或温度缩放修复的成分。

四、分配建议的重新解读

表 4-1 T4：分配收益 DE(k2)−Single 在两种选择规则下（配对，n=10）

预算	final 规则收益	p	ES 规则收益	p	缩水倍数
B30	−0.0730	0.0020	−0.0369	0.0020	2.0×
B60	−0.1948	0.0020	−0.0173	0.0020	11.3×
B120	−0.2515	0.0020	+0.0651（反转）	0.0020	符号反转

表 4-2 早停 Single 与各 k 配置的对照（测试 NLL，n=10 均值；DE 取 S1 存档）

预算	ES-Single	DE(k2)	DE(k3)	DE(k5)	DE(k8)	最优
B30	0.3434	0.3065	0.3041	0.3161	—	DE(k3)

预算	ES-Single	DE(k2)	DE(k3)	DE(k5)	DE(k8)	最优
B60	0.3491	0.3317	0.3020	0.2974	—	DE(k5)
B120	0.3506	0.4157	0.3355	0.2965	0.2909	DE(k8)

三点解读。其一，方向不变：三个预算下最优配置均为 DeepEns（B30 k3 / B60 k5 / B120 k8），与主网格的 k*(B) 结论一致——早停不改变“分配应偏向多成员”的方向性建议。其二，幅度剧变且符号反转：DE(k2) 在 B120 处被早停 Single 反超（0.4157 vs 0.3506，差 +0.0651，p=0.0020）——k2 的每个成员各训 60 epochs、按最终权重取值，双双停在过训区；一个停在验证最优的 120-epoch 单模型同时胜过它们这是 v5 首次出现“集成配置被 Single 明确击败”的设置，其成因全部归于选择规则。其三，机制分解：把 final 规则的 DE−SG 收益减去 ES 规则下的同项，差值即“成员隐式早停”的贡献——B120 处为 0.2515−(−0.0651)≈0.32 nats 的表观收益中，早停校正后仅剩 0.06（DE(k8) 0.2909 vs ES-Single 0.3506）。DeepEns 相对早停 Single 的净优势（约 0.05–0.06 nats）才是独立重启的纯多样性贡献，且该净值在三个预算上几乎恒定（B30 0.039 / B60 0.052 / B120 0.060，均以各自最优 k 计）。

表 4-2 的 k 扫描对照为消融内的探索性对比（A1 预注册仅指定 ES vs final 主对比），不进入主网格假设判定；其作用是把 T4 的 k2 反转放到全 k 谱系中定位，防止“集成不如单模型”的过度概括。

五、选择行为与校准

表 5-1 验证最优 epoch 的分布（n=10）

预算	均值	中位数	范围	逐种子值
B30	12.1 ± 2.1	12	[8, 15]	12, 13, 12, 12, 12, 10, 15, 12, 8, 15
B60	10.9 ± 2.6	11.5	[7, 14]	8, 13, 12, 12, 12, 11, 7, 14, 7, 13
B120	10.7 ± 1.6	10.5	[8, 13]	8, 11, 10, 11, 10, 11, 13, 9, 11, 13

验证最优 epoch 集中在 7–15 且随预算增大轻微左移（12.1 → 10.9 → 10.7），与 Doc 3 第四节可行性论证引用的“FMNIST 验证最优 epoch 中位约 12”一致；这同时解释了 e 甜区的左端（S1/S3 的成员级曲线显示 e<10 的成员开始欠拟合）——甜区左边界与验证最优 epoch 本是同一现象的两侧。选择行为的稳定性（sd ≈ 2 epochs）意味着早停规则在实践中是低方差的：不需要精调停止点，验证曲线在最优附近相当平坦。

表 5-2 温度缩放后的两规则对比（TS-NLL，n=10 均值 ± 标准差）

预算	ES + TS	final + TS	TS 后差距 ES−final	raw 差距（参照）	TS 吸收比例
B30	0.3249 ± 0.0088	0.3126 ± 0.0028	+0.0123	−0.0361	—（final 已略优）
B60	0.3351 ± 0.0089	0.3325 ± 0.0050	+0.0026	−0.1774	99%
B120	0.3368 ± 0.0051	0.3485 ± 0.0061	−0.0117	−0.3166	96%

温度缩放与早停在 B60/B120 上近乎可互换（吸收比例 99%/96%），在 B30 上 TS 后 final 反而略优 0.012——短预算的轻微过训经温度校正后，其更长的有效训练反而占优。两个修复手段的组合（ES + TS，0.3368）是 B120 处四组合中最优的，但与 final + TS（0.3485）的差距仅 0.012，处于实践可忽略区。结论：后期恶化的主体是温度型过度自信（H5 机制的极端形式），任何单靠校准修复的手段（TS）或回避后期训练的手段（早停）都能消除其大部分；早停在 B30 略有代价（选中的模型训练不足），TS 则无此代价。

六、A2：推理成本基准（H6）

H6（Doc 3 表 3-1）：预测平均的延迟/内存/存储随 k 线性增长；给出实测数字，仅描述性，无失败判据，且必须与训练预算分开报告。基准覆盖主网格两个模型族（FMNIST MLP 109,386 参数；CIFAR-10 SmallCNN 33,834 参数），成员数 k∈{1,2,3,5,8}（网格值加 k=1 即 Single），批大小 1 与 256，双线程 CPU。延迟按主引擎的预测管线计时（成员常驻、float32 前向、numpy float64 概率平均），报告重复 30–400 次的中位数（mean±sd 见 JSON 存档；batch=1 的 mean 受偶发调度抖动影响，中位数更稳健）。延迟只依赖（架构，批大小，k）——FLOPs 固定、无数据依赖分支——故用合成正态张量（已存档注明）。

表 6-1 概率平均的推理延迟（中位数，ms；k 为成员数）

模型族	batch	k=1	k=2	k=3	k=5	k=8	线性拟合	R^2
MLP-FMNIST	1	0.041	0.076	0.113	0.213	0.371	0.069 ms/成员	0.9943
MLP-FMNIST	256	0.403	0.778	1.153	1.909	3.027	0.556 ms/成员	0.9876
CNN-CIFAR10	1	0.276	0.571	0.846	1.440	2.302	0.411 ms/成员	0.9969
CNN-CIFAR10	256	34.92	94.23	130.09	225.98	384.43	48.024 ms/成员	0.9998

表 6-2 参数量、权重存储与常驻内存

模型族	参数量/模型	fp32 权重/模型	k=2 / 3 / 5 / 8 存储	RSS 差分（8 模型）
MLP-FMNIST	109,386	0.438 MB	0.88 / 1.31 / 2.19 / 3.50 MB	3.5 MB（与 8×0.438 吻合）
CNN-CIFAR10	33,834	0.135 MB	0.27 / 0.41 / 0.68 / 1.08 MB	≈0 MB（小于分配器粒度）

H6 的描述性结论全部成立：延迟对 k 的线性拟合 R^2 介于 0.988 与 0.9998，截距可忽略（MLP −0.04 至 −0.11 ms；CNN −0.03 至 −3.6 ms，相对斜率 <8%）；权重存储严格按 k 线性（每成员 0.438/0.135 MB）；常驻内存的实测差分与确定性字节数一致。绝对数字给出部署参照：MLP 族 batch=256 时每增加一个成员多 0.556 ms（每样本 2.2 μs），8 成员全程 3.0 ms；CNN 族每成员 48 ms（每样本 188 μs），8 成员 384 ms——CNN 的每成员成本是 MLP 的 86 倍，成员数选择的成本敏感度高度依赖模型族的每样本算力。与训练预算的分离报告（Doc 3 表 5-1）由此完成：B=60 的训练预算下，k=8 的推理成本是 k=1 的 8 倍（线性、无亚线性），任何“多成员更优”的建议都必须把这一列与 NLL 列并排呈现。

七、机制综合：选择规则作为分配相图的隐藏维度

A1 的发现并入 S1–S3 的分配相图后，v5 的机制结构完成最后一块拼图。原相图有两条轴：预算轴（B30–B240，S1/S2）与域轴（MNIST/FMNIST/CIFAR-10，S3），刻画分配收益 = f(单模型余量)。A1 揭示第三条隐藏轴——选择规则轴：同一训练轨迹、同一预算、同一架构，仅因取权重的时间点不同，单模型 NLL 在 B120 处相差 0.3166（0.3506 vs 0.6672）。三轴的关系并非独立叠加：选择规则轴在近饱和域（MNIST，无过度自信恶化）上预期近零，在高难度域（CIFAR，恶化的温度成分更大）上预期更大——它与域轴通过“后期过度自信”这同一机制耦合，与预算轴通过“恶化随 B 单调积累”耦合。

对 DeepEns 的机制分解由此获得三重拆分：final 规则下的表观分配收益 =（成员隐式早停的贡献）+（独立多样性的净贡献）+（随机性平均的方差缩减）。A1 把第一项从 B120 的 0.32 中剥离出来，留下约 0.06 的净贡献；结合 S3 的域轴证据（净贡献随域难度放大：MNIST ≈ 0.009、FMNIST ≈ 0.06、CIFAR ≈ 1.14——以各域最优 k 与 final 规则计，MNIST/CIFAR 未做早停消融，其数字为 final 规则下的下界），独立重启的价值谱系与单模型余量谱系同向。这一分解对实践的含义直接：若部署方已使用验证集早停（几乎所有现代训练管线的默认），主网格的 DE−SG 数字高估了切换到集成可获得的收益，真实可得的净收益约为表观值减去早停修复量；温度缩放在场时同理（B120：0.2515 的表观收益经 TS 后仅剩 0.012 的对应项）。论文的重

写须把“分配建议”明确条件化于选择规则——这是 v5 相对 v4 及既有文献的关键增量之一。

八、预注册假设判定更新（A1/A2 收尾）

表 8-1 假设与研究问题判定对照（判据原文见 Doc 3 表 3-1 / 第一节）

项	A1/A2 数据	判定更新
H6 推理成本（延迟/内存/存储随 k 线性）	延迟线性 R^2 0.988–0.9998；存储 k×0.438/0.135 MB；RSS 差分与字节数吻合；绝对数字已与训练预算分离报告	支持（描述性判据全部满足；无失败判据，闭环）
RQ5 选择规则是否改变基础事实	早停使 B30→120 恶化由 +0.2877 缩至 +0.0072（< δ=0.010）；TS 吸收两规则差距 96–99%；B120 处 DE(k2) 被 ES-Single 反超	是——基础事实是选择规则的产物；分配建议须条件化于选择规则（净收益 ≈ 表观收益 − 早停修复量）
H2 放大机制（条件命题，S2 判 D6）	A1 补充：放大差距的 Single 端在早停下消失，放大由“规则×后期过度自信”交互驱动	维持 D6 条件命题；机制分解深化
H5 温度缩放（压缩不消除）	TS 与早停近可互换（B60/B120 吸收 96–99%）；ES+TS 组合最优	维持部分支持；选择规则维度第三重确认

至此预注册实验网格（S1+S2+S3+A1+A2 = 22 个网格单元 + 3 个消融单元 + 1 个基准脚本）全部完成，六项假设（H1–H6）与五项研究问题（RQ1–RQ5）全部有数据支撑的判定。无新增偏离预注册判据的情况；全局停止规则三条件均未命中。

九、偏离登记（A1/A2 新增）

编号	偏离	处置
D15	A1 引擎为独立复制的训练循环（run_ablation_earlystop.py）而非修改共享 common.py 的 train_run	避免牵连 v1/v2/SWA/S3 引擎；复制正确性由 360 个位级锚点（final vs S1，含 TS 的 T 与 val-NLL）数据级验证，I4/I5 全过
D16	A1 早停的平局规则（严格更小者胜、平局取最早 epoch）在引擎 docstring 与配置戳中预先写明，但 Doc 3 未显式规定平局处理	按标准早停惯例预先固定并全程唯一使用；I6 对每条记录核验规则执行一致
D17	A2 使用合成正态张量而非真实测试图像（延迟只依赖架构/批大小/k，FLOPs 与权重值无关）；RSS 差分在 CNN 族小于内存分配器粒度不可测	JSON 存档逐表注明；存储列改用确定性字节数（参数量 × fp32），MLP 族的 RSS 差分与字节数吻合作交叉验证
D18	A1 实测 0.27 h（978 s）vs Doc 3 估算 ≈0.5 h；表 4-2 的 k 扫描对照超出 A1 预注册主对比范围	预算内完成；k 扫描标注为探索性对比，不进入主网格假设判定

十、论文重写：数据就绪与输入清单

全部预注册数据就绪，论文 v5 全文重写为唯一剩余工作。A1/A2 对重写的三点核心输入：其一，摘要与讨论必须包含选择规则的条件化——“分配收益的表观值依赖最终权重规则；在早停或温度缩放在场时，净收益约为表观值减去校准修复量（FMNIST B120：0.25 → 0.06/0.01）”；其二，A2 的成本列与 NLL 列并排呈现（每成员边际延迟 MLP 0.556 ms vs CNN 48 ms，batch=256），把“成员数选择”明确为质量-多样性-成本的三元权衡；其三，机制叙事升级为三轴相图（预算 × 域 × 选择规则），其中选择规则轴为本工作新增维度，MNIST/CIFAR 上的早停消融可作为未来工作的边界探针（本阶段仅 FMNIST）。

表 10-1 全网格数据资产与论文对应关系

数据块	内容	论文对应
S1 主网格（14 单元）	FMNIST B30–B120 × k2–k8，H1/H2/H3 判定	主结果：k 曲线、放大规律、快照差距
S2 外推（4 单元）	FMNIST B240 × k2–k8，G2 通过	外推验证：放大趋势延续至 B240
S3 跨域（4 单元）	MNIST/CIFAR-10，H4/G3 通过	边界条件：域谱系与 e 甜区跨域
A1 消融（3 单元）	FMNIST B30/60/120 早停 Single，RQ5	机制分解：选择规则轴、净多样性收益
A2 基准（1 脚本）	双模型族延迟/存储，H6	成本列：k 的部署代价

十一、可核验性

- 原始记录：ijmlc-repo/results/a1/experiment_v5_a1_fmnist_B{30,60,120}.jsonl（30 条逐种子记录：best_epoch、ES/final 全指标、逐 epoch 历史、版本戳）；ijmlc-repo/results/a2/benchmark_inference.json（双族延迟分布、线性拟合、存储/RSS）
- 分析输出：results/a1/analysis_v5_a1a2.json（T1–T5 配对对比与 95% CI、A2 汇总）、summary_v5_a1.csv、summary_v5_a2_latency.csv、summary_v5_a2_cost.csv
- 脚本：code/run_ablation_earlystop.py（A1 引擎）、scripts/benchmark_inference.py（A2 基准）、scripts/check_a1_integrity.py（七项核验）、scripts/analyze_a1a2.py（分析，置换检验与 analyze_s3.py 同实现）
- 复现命令：python code/run_ablation_earlystop.py --budget B --seeds 0:10 --out <path> --time-budget 500（B∈{30,60,120}）；python scripts/benchmark_inference.py；python scripts/check_a1_integrity.py；python scripts/analyze_a1a2.py

- 位级锚点：final vs S1 single 30 种子 × 12 指标逐位相等（I4/I5）；best_epoch 与 Doc 3 §4 预估（中位约 12）一致；本报告全部数值与 analysis_v5_a1a2.json 逐项对应